

طبقه‌بندی سرطان پوست در سطح متخصص پوست با استفاده از شبکه‌های عصبی عمیق

آندره استوا¹⁸، برت کوپرل¹⁹، رابرتو آ. ئووا²³، جاستین کو²، سوزان ام. سوئتر²⁴، هلن ام. بلانو³ و سباستین ثرون⁵

سرطان پوست، شایع‌ترین بدخیمی انسان¹⁻⁴ است، که در درجه اول به صورت بصری تشخیص داده می‌شود و با غربالگری بالینی اولیه آغاز می‌گردد و به دنبال آن ممکن است تحلیل درموسکوپی، بیوپسی و بررسی هیستوپاتولوژیک انجام شود. طبقه‌بندی خودکار ضایعات پوستی با استفاده از تصاویر به دلیل تغییرات ظریف در ظاهر ضایعات پوستی، کاری چالش‌برانگیز است. شبکه‌های عصبی کانولوشنی عمیق (CNN)⁴⁵ (پتانسیل خود را برای انجام وظایف کلی و بسیار متغیر در بین دسته‌بندی‌های ظریف اشیاء نشان داده‌اند⁶⁷⁸⁷. در اینجا ما طبقه‌بندی ضایعات پوستی را با استفاده از یک CNN منفرد نشان می‌دهیم که مستقیماً و به صورت «انتهای به انتهای» از روی تصاویر آموزش دیده است و تنها از پیکسل‌ها و برجسب‌های بیماری به عنوان ورودی استفاده می‌کند. ما یک CNN را با استفاده از یک مجموعه داده شامل ۱۲۹,۴۵۰ تصویر بالینی آموزش دادیم - که دو مرتبه قدر بزرگتر از مجموعه داده‌های قبلی¹⁷⁸⁷ است - و متشکل از ۲,۰۳۲ بیماری مختلف. عملکرد آن را در برابر ۲۱ متخصص پوست دارای مورد تخصصی، روی تصاویر بالینی ثابت‌شده با بیوپسی، با دو مورد استفاده حیاتی طبقه‌بندی دوگانه آزمایش کردیم: کارسینوم‌های کراتینوسایت در مقابل کراتوز سبورئیک خوش‌خیم؛ و ملانوم‌های بدخیم در مقابل خال‌های (نووس) خوش‌خیم. مورد اول نمایانگر شناسایی شایع‌ترین سرطان‌ها و مورد دوم نمایانگر شناسایی کشنده‌ترین سرطان پوست است CNN. در هر دو کار به عملکردی هم‌تراز با تمام متخصصان آزمایش‌شده دست یافت که نشان‌دهنده یک هوش مصنوعی قادر به طبقه‌بندی سرطان پوست با سطحی از شایستگی قابل مقایسه با متخصصان پوست است. با تجهیز دستگاه‌های همراه به شبکه‌های عصبی عمیق، امکان گسترش دسترسی متخصصان پوست فراتر از محیط کلینیک فراهم می‌شود. پیش‌بینی می‌شود که تا سال ۲۰۲۱ (منبع ۱۳) ۶.۳ میلیارد اشتراک تلفن هوشمند وجود خواهد داشت و بنابراین این فناوری به طور بالقوه می‌تواند دسترسی جهانی کم‌هزینه به مراقبت‌های تشخیصی حیاتی را فراهم کند.

هر ساله ۵.۴ میلیون مورد جدید سرطان پوست در ایالات متحده² رخ می‌دهد. از هر پنج آمریکایی، یک نفر در طول عمر خود با یک بدخیمی پوستی تشخیص داده خواهد شد. اگرچه ملانوم‌ها کمتر از ۵٪ از کل سرطان‌های پوست را در ایالات متحده تشکیل می‌دهند، اما مسئول تقریباً ۷۵٪ از کل مرگ‌های مرتبط با سرطان پوست هستند و تنها در ایالات متحده سالانه بیش از ۱۰,۰۰۰ مرگ را سبب می‌شوند. تشخیص زودهنگام بسیار حیاتی است، زیرا نرخ بقای ۵ ساله تخمینی برای ملانوم از بیش از ۹۹٪ اگر در مراحل اولیه تشخیص داده شود، به حدود ۱۴٪ اگر در مراحل آخر تشخیص داده شود، کاهش می‌یابد. ما یک روش محاسباتی توسعه داده‌ایم که ممکن است به پزشکان و بیماران اجازه دهد ضایعات پوستی را به طور فعال دنبال کرده و سرطان را زودتر تشخیص دهند. با ایجاد یک تاکسونومی جدید برای بیماری‌ها و یک الگوریتم تقسیم‌بندی بیماری که بیماری‌های فردی را به کلاس‌های آموزشی نگاشت می‌دهد، قادر به ساخت یک سیستم یادگیری عمیق برای درماتولوژی خودکار هستیم.

کارهای قبلی در طبقه‌بندی رایانه‌ای کمکی درماتولوژی¹⁵⁴⁴⁵ به دلیل داده‌های ناکافی و تمرکز بر وظایف استاندارد شده مانند درموسکوپی¹⁶⁷⁸⁷ و طبقه‌بندی تصاویر هیستولوژیکی¹⁹⁷⁸⁷، فاقد قابلیت تعمیم‌پذیری پزشکان بوده است. تصاویر درموسکوپی از طریق یک ابزار تخصصی گرفته می‌شوند و تصاویر هیستولوژیکی از طریق بیوپسی تهاجمی و میکروسکوپی به دست می‌آیند؛ که هر دو روش، تصاویر به شدت استاندارد شده‌ای تولید می‌کنند. تصاویر عکاسی (مثلاً تصاویر تلفن هوشمند) تغییرپذیری در عواملی مانند زوم، زاویه و نوردهی نشان می‌دهند که طبقه‌بندی را به طور قابل توجهی چالش‌برانگیزتر می‌کند²⁵⁴⁴⁴. ما بر این چالش با استفاده از یک رویکرد مبتنی بر داده غلبه می‌کنیم - ۱.۴۱ میلیون تصویر پیش‌آموزش و آموزش، طبقه‌بندی را در برابر تغییرپذیری عکاسی مقاوم می‌سازد. بسیاری از تکنیک‌های قبلی قبل از طبقه‌بندی نیازمند پیش‌پردازش گسترده، قطع‌بندی ضایعه و استخراج ویژگی‌های خاص حوزه هستند. در مقابل، سیستم ما به هیچ ویژگی دست‌ساز نیازی ندارد؛ این سیستم به صورت انتهای به انتهای مستقیماً از برجسب‌های تصویر و پیکسل‌های خام آموزش دیده است و از یک شبکه واحد برای هر دو نوع تصویر عکاسی و درموسکوپی استفاده می‌کند. مجموعه کارهای موجود از مجموعه داده‌های کوچکی با معمولاً کمتر از هزار تصویر از ضایعات پوستی¹⁶⁴⁴⁶ استفاده می‌کنند که در نتیجه به خوبی به تصاویر جدید تعمیم نمی‌یابند. ما طبقه‌بندی قابل تعمیم را با یک مجموعه داده جدید

برچسب‌گذاری‌شده توسط متخصصان پوست شامل ۱۲۹,۴۵۰ تصویر بالینی، از جمله ۳,۳۷۴ تصویر درموسکوپی، نشان می‌دهیم.

الگوریتم‌های یادگیری عمیق، که با پیشرفت‌های محاسباتی و مجموعه‌داده‌های بسیار بزرگ²⁵ قدرتمند شده‌اند، اخیراً نشان داده‌اند که در وظایف بصری مانند بازی آتاری²⁶، بازی‌های صفحه‌ای استراتژیک مانند گو²⁷ و تشخیص اشیاء⁶⁸⁷ از عملکرد انسان پیشی می‌گیرند. در این مقاله، ما توسعه یک CNN را شرح می‌دهیم که عملکرد متخصصان پوست را در سه وظیفه تشخیصی کلیدی مطابقت می‌دهد: طبقه‌بندی ملانوم، طبقه‌بندی ملانوم با استفاده از درموسکوپی و طبقه‌بندی کارسینوم. مقایسه‌ها را به طبقه‌بندی مبتنی بر تصویر محدود می‌کنیم.


ما از معماری CNN اینسپشن v3 گوگل‌نت⁶⁹ استفاده می‌کنیم که پیش‌تر روی حدود ۱.۲۸ میلیون تصویر (۱,۰۰۰ دسته شیء) از چالش تشخیص بصری در مقیاس بزرگ ImageNet 2014⁶ آموزش دیده بود و آن را با استفاده از یادگیری انتقالی²⁸⁸ روی مجموعه‌داده خود آموزش می‌دهیم. شکل ۱ سیستم در حال کار را نشان می‌دهد. CNN با استفاده از ۷۵۷ کلاس بیماری آموزش دیده است. مجموعه‌داده ما متشکل از تصاویر برچسب‌گذاری‌شده توسط متخصصان پوست است که در یک تاکسونومی درختی ساختارمند از ۲,۰۳۲ بیماری سازمان‌دهی شده‌اند، که در آن بیماری‌های فردی گره‌های برگ را تشکیل می‌دهند. تصاویر از ۱۸ مخزن آنلاین دسترسی‌پذیر مختلف گردآوری شده توسط پزشک، و همچنین از داده‌های بالینی مرکز پزشکی دانشگاه استنفورد می‌آیند. شکل ۲ زیرمجموعه‌ای از تاکسونومی کامل را نشان می‌دهد که توسط متخصصان پزشکی بر اساس بالین و شباهت بصری سازمان‌دهی شده است. مجموعه‌داده خود را به ۱۲۷,۴۶۳ تصویر آموزش و اعتبارسنجی و ۱,۹۴۲ تصویر آزمایش برچسب‌گذاری‌شده با بیوپسی تقسیم می‌کنیم.

برای استفاده از اطلاعات ظریف موجود در ساختار تاکسونومی، الگوریتمی توسعه می‌دهیم (جدول داده‌های گسترده ۱) تا بیماری‌ها را به کلاس‌های آموزشی ظریف (مثلاً ملانوم آمelanotیک و ملانوم آکرولنتیگینوس) تقسیم کند. در زمان استنتاج، CNN یک توزیع احتمال روی این کلاس‌های ظریف خروجی می‌دهد. برای بازیابی احتمالات کلاس‌های کلی‌تر مورد علاقه (مثلاً ملانوم)، احتمالات زیرشاخه‌های آن‌ها را جمع می‌کنیم (برای جزئیات بیشتر به بخش روش‌ها و شکل داده‌های گسترده ۱ مراجعه کنید).

ما اثربخشی الگوریتم را به دو روش، با استفاده از اعتبارسنجی متقابل نهایی بررسی می‌کنیم. ابتدا، الگوریتم را با استفاده از یک تقسیم‌بندی سه‌کلاسه بیماری - گره‌های سطح اول تاکسونومی که نمایانگر ضایعات خوش‌خیم، ضایعات بدخیم و ضایعات غیرنئوپلاستیک هستند - اعتبارسنجی می‌کنیم.

¹ گروه مهندسی برق، دانشگاه استنفورد، استنفورد، کالیفرنیا، ایالات متحده. ² گروه درماتولوژی، دانشگاه استنفورد، استنفورد، کالیفرنیا، ایالات متحده. ³ گروه پاتولوژی، دانشگاه استنفورد، کالیفرنیا، ایالات متحده. ³ سرویس درماتولوژی، سیستم مراقبت بهداشتی اداره امور کهنه‌سربازان پالو آلتو، پالو آلتو، کالیفرنیا، ایالات متحده. ³ آزمایشگاه بکستر برای زیست‌شناسی سلول‌های بنیادی، گروه میکروبیولوژی و ایمونولوژی، مؤسسه زیست‌شناسی و پزشکی باززایی سلول‌های بنیادی، دانشگاه استنفورد، استنفورد، کالیفرنیا، ایالات متحده. ³ گروه علوم کامپیوتر، دانشگاه استنفورد، استنفورد، کالیفرنیا، ایالات متحده.

• این نویسندگان به طور یکسان در این کار مشارکت داشته‌اند.



پژوهش

ضایعات. در این وظیفه، CNN به دقت کلی $72.1 \pm 0.9\%$ (میانگین $\pm$ انحراف معیار) (میانگین دقت‌های استنتاج کلاس‌های فردی) می‌رسد و دو متخصص پوست به ترتیب به دقت‌های 65.56% و 66.0% روی یک زیرمجموعه از مجموعه اعتبارسنجی دست می‌یابند. دوم، الگوریتم را با استفاده از یک تقسیم‌بندی نه‌کلاسه بیماری - گره‌های سطح دوم - اعتبارسنجی می‌کنیم، به طوری که بیماری‌های هر کلاس برنامه‌های درمانی پزشکی مشابهی داشته باشند. CNN به دقت کلی $55.4 \pm 1.7\%$ می‌رسد در حالی که همان دو متخصص پوست به دقت‌های 53.3% و 55.0% دست می‌یابند. یک CNN آموزش دیده روی یک تقسیم‌بندی ظریف‌تر بیماری، بهتر از یک CNN آموزش دیده مستقیم روی سه یا نه کلاس عمل می‌کند (جدول داده‌های گسترده ۲ را ببینید)، که اثربخشی الگوریتم تقسیم‌بندی ما را نشان می‌دهد. از آنجایی که تصاویر مجموعه اعتبارسنجی توسط متخصصان پوست برچسب‌گذاری شده‌اند، اما لزوماً با بیوپسی تأیید نشده‌اند، این معیار نتیجه‌گیری قطعی نیست و در عوض نشان می‌دهد که CNN در حال یادگیری اطلاعات مرتبط است.

a




برای اعتبارسنجی قطعی الگوریتم، ما با استفاده از تنها تصاویر ثابت شده با بیوپسی روی موارد استفاده مهم پزشکی، آزمایش کردیم که آیا الگوریتم و متخصصان پوست می‌توانند ضایعات بدخیم در مقابل خوش‌خیم منشأ اپیدرمی (کارسینوم کراتینوسایت در مقایسه با کراتوز سبورئیک خوش‌خیم) یا ملانوسیتی (ملانوم بدخیم در مقایسه با خال خوش‌خیم) را تمایز دهند یا خیر. برای ضایعات ملانوسیتی، ما دو آزمایش نشان می‌دهیم، یکی با استفاده از تصاویر استاندارد و دیگری با استفاده از تصاویر درموسکوپی، که دو گامی را که یک متخصص پوست ممکن است برای به دست آوردن یک برداشت بالینی انجام دهد، منعکس می‌کنند. همان CNN برای هر سه وظیفه استفاده می‌شود. شکل ۲ b چند تصویر نمونه نشان می‌دهد که دشواری در تمایز بین ضایعات بدخیم و خوش‌خیم، که بسیاری از ویژگی‌های بصری را به اشتراک می‌گذارند، را نشان می‌دهد. معیارهای مقایسه ما حساسیت و ویژگی هستند:


$$\text{حساسیت} = \frac{\text{مثبت واقعی}}{\text{کل مثبت}}$$

$$\text{ویژگی} = \frac{\text{منفی واقعی}}{\text{کل منفی}}$$


که در آن «مثبت واقعی» تعداد ضایعات بدخیم به درستی پیش‌بینی شده، «مثبت» تعداد ضایعات بدخیم نمایش داده شده، «منفی واقعی» تعداد ضایعات خوش‌خیم به درستی پیش‌بینی شده، و «منفی» تعداد ضایعات خوش‌خیم نمایش داده شده است. هنگامی که یک مجموعه آزمایش از طریق CNN تغذیه می‌شود، برای هر تصویر یک احتمال، P ، از بدخیمی خروجی می‌دهد. ما می‌توانیم حساسیت و ویژگی این احتمالات را با انتخاب یک آستانه احتمال t و تعریف پیش‌بینی $\hat{y}$ برای هر تصویر به صورت $\hat{y} = P \geq t$ محاسبه کنیم. با تغییر t در بازه ۰-۱، منحنی‌ای از حساسیت‌ها و ویژگی‌هایی که CNN می‌تواند به آن‌ها دست یابد، ایجاد می‌شود.

b





عملکرد مستقیم CNN و حداقل ۲۱ متخصص پوست دارای مورد تخصصی را روی طبقه‌بندی ضایعات اپیدرمی و ملانوسیتی مقایسه کردیم (شکل ۳). (a) برای هر تصویر از متخصصان پوست پرسیده شد که آیا ضایعه را بیوپسی/درمان کنند یا به بیمار اطمینان خاطر دهند. هر نقطه قرمز روی نمودارها نمایانگر حساسیت و ویژگی یک متخصص پوست منفرد است. CNN از هر متخصص پوستی که نقطه حساسیت و ویژگی آن زیر منحنی آبی CNN قرار گیرد، عملکرد بهتری دارد، که نقطه اکثر آن‌ها همینطور است. نقاط سبز نمایانگر میانگین متخصصان پوست (میانگین حساسیت و ویژگی تمام نقاط قرمز) هستند، با میله‌های خطا که یک انحراف معیار را نشان می‌دهند. مساحت زیر منحنی (AUC) برای هر مورد بیش از ۹۱٪ است. تصاویر این مقایسه (۱۳۵ تصویر اپیدرمی، ۱۳۰ تصویر ملانوسیتی و ۱۱۱ تصویر درموسکوپی ملانوسیتی) از مجموعه‌های آزمایش کامل نمونه‌گیری شده‌اند. منحنی‌های حساسیت و ویژگی برای کل مجموعه آزمایش تصاویر برچسب‌گذاری شده با بیوپسی ما شامل ۷۰۷ تصویر اپیدرمی، ۲۲۵ تصویر ملانوسیتی و ۱,۰۱۰ تصویر درموسکوپی ملانوسیتی بود (شکل ۳). (b) تغییرات ناچیزی در $AUC (<0.03)$ مشاهده کردیم هنگامی که مجموعه داده نمونه (شکل ۳) را با مجموعه داده کامل (شکل ۳) مقایسه کردیم که قابلیت اطمینان نتایج ما روی یک مجموعه داده بزرگتر را تأیید می‌کند. در یک تحلیل جداگانه با نتایج مشابه (به بخش روش‌ها مراجعه کنید) از متخصصان پوست پرسیده شد که آیا فکر می‌کنند یک ضایعه بدخیم است یا خوش‌خیم.



ما ویژگی‌های داخلی یادگرفته شده توسط CNN را با استفاده از t-SNE (جاسازی تصادفی همسایه توزیع شده)²⁹ بررسی کردیم (شکل ۴). هر نقطه نمایانگر یک تصویر ضایعه پوستی است که از خروجی ۲۰۴۸ بعدی آخرین لایه پنهان CNN به دو بعد نگاشت شده است. ما خوشه‌هایی از نقاط با کلاس‌های بالینی یکسان را می‌بینیم (شکل ۴، درج‌ها تصاویر بیماری‌های مختلف را نشان می‌دهند). کارسینوم‌های سلول پایه و سنگفرشی در سرتاسر این نقطه‌ای اپیدرمی بدخیم پراکنده شده‌اند. ملانوم‌ها در مرکز خوشه می‌کنند، در مقابل خال‌ها (نوی) که در سمت راست خوشه می‌کنند. به طور مشابه، کراتوزهای سبورئیک در مقابل هم‌تایان بدخیم خود خوشه می‌کنند.

در اینجا ما اثر بخشی یادگیری عمیق در درماتولوژی را نشان می‌دهیم، تکنیکی که ما آن را هم برای شرایط عمومی پوست و هم برای سرطان‌های خاص به کار می‌بریم. با استفاده از یک شبکه عصبی کانولوشنی منفرد آموزش دیده روی طبقه‌بندی عمومی ضایعات پوستی، عملکرد حداقل ۲۱ متخصص پوست آزمایش شده در سه وظیفه تشخیصی حیاتی را مطابقت می‌دهیم: طبقه‌بندی کارسینوم کراتینوسایت، طبقه‌بندی ملانوم و طبقه‌بندی ملانوم با استفاده از درموسکوپی. این روش سریع و مقیاس‌پذیر روی دستگاه‌های همراه استقرار می‌یابد و پتانسیل تأثیر بالینی قابل توجهی دارد، از جمله گسترش دامنه تمرین مراقبت‌های اولیه و تقویت تصمیم‌گیری بالینی برای متخصصان درماتولوژی. پژوهش بیشتر برای ارزیابی عملکرد در یک محیط واقعی و بالینی ضروری است، تا این تکنیک در سرتاسر توزیع کامل و طیف ضایعاتی که در عمل معمول با آن‌ها مواجه می‌شود، اعتبار سنجی شود. در حالی که ما تصدیق می‌کنیم که برداشت و تشخیص بالینی یک متخصص پوست بر اساس عوامل زمینه‌ای فراتر از بازرسی بصری و درموسکوپی یک ضایعه به طور مجزا است، توانایی طبقه‌بندی تصاویر ضایعات پوستی با دقت یک متخصص پوست دارای بورد تخصصی، پتانسیل گسترش عمیق دسترسی به مراقبت پزشکی حیاتی را دارد. این روش در درجه اول توسط داده محدود شده است و می‌تواند بسیاری از شرایط بصری را در صورت وجود نمونه‌های آموزشی کافی طبقه‌بندی کند. یادگیری عمیق نسبت به نوع داده تصویری استفاده شده بی‌طرف است و می‌تواند برای سایر تخصص‌ها، از جمله چشم‌پزشکی، گوش و حلق و بینی، رادیولوژی و پاتولوژی تطبیق یابد.

محتوی آنالین روش‌ها، به همراه هر مورد نمایش داده‌های گسترده و داده منبع اضافی، در نسخه آنالین مقاله در دسترس هستند؛ منابع منحصر به این بخش‌ها تنها در مقاله آنالین ظاهر می‌شوند.

(References):

1. American Cancer Society. Cancer facts & figures 2016. Atlanta, American Cancer Society 2016.
<http://www.cancer.org/acs/groups/content@research/documents/document/acspc-04779.pdf>.
2. Rogers, H. W. et al. Incidence estimates of nonmelanoma skin cancer (keratinocyte carcinomas) in the US population, 2012. *JAMA Dermatology* **151.10**, 1081–1086 (2015).
3. Stern, R. S. Prevalence of a history of skin cancer in 2007: results of an incidence-based model. *Arch. Dermatol.* **146**, 279–282 (2010).
4. LeCun, Y., Bengio, Y., & Hinton, G. Deep learning. *Nature* **521**, 436–444 (2015).
5. LeCun, Y., & Bengio, Y. In *The Handbook of Brain Theory and Neural Networks* (ed. Arbib, M. A.) 3361.10 (MIT Press, 1995).
6. Russakovsky, O. et al. Imagenet large scale visual recognition challenge. *Int. J. Comput. Vis.* **113**, 211–252 (2015).
7. Krizhevsky, A., Sutskever, I., & Hinton, G. E. Imagenet classification with deep convolutional neural networks. *Adv. Neural Inf. Process. Syst.* **25**, 1097–1105 (2012).
8. Ioffe, S., & Szegedy, C. Batch normalization: accelerating deep network training by reducing internal covariate shift. *Proc. 32nd Int. Conference on Machine Learning* 446–456 (2014).
9. Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. Rethinking the inception architecture for computer vision. Preprint at <https://arxiv.org/abs/1512.00567> (2015).
10. Szegedy, C. et al. Going deeper with convolutions. *Proc. IEEE Conference on Computer Vision and Pattern Recognition* 1–9 (2015).
11. He, K. Zhang, X. Ren, S. & Sun J. Deep residual learning for image recognition. Preprint at <https://arxiv.org/abs/1512.03385> (2015).
12. Masood, A. & Al-Jumally, A. A. Computer aided diagnostic support system for skin cancer: a review of techniques and algorithms. *Int. J. Biomed. Imaging* **2013**, 323268 (2013).
13. Cervall, P., & Report, E. M. Ericsson mobility report
<https://www.ericsson.com/res/docs/2016/ericsson-mobility-report-2016.pdf> (2016).
14. Rosado, B. et al. Accuracy of computer diagnosis of melanoma: a quantitative meta-analysis. *Adv. Dermatol.* **139**, 361–367, discussion 366 (2003).
15. Burroni, M. et al. Melanoma computed aided diagnosis: reliability and feasibility study. *Chin. Cancer Res.* **10**, 1881–1886 (2004).
16. Kittler, H., Penarrubia, F., Wolf, K., & Binder, M. Diagnostic accuracy of dermoscopy. *Lancet Oncol.* **3**, 159–165 (2002).
17. Codella, N. et al. In *Machine Learning in Medical Imaging* (eds Zhou, L., Wang, L., Wang, Q., & Shi, J.) 118–126 (Springer, 2015).

18. Gutman, D. et al. Skin lesion analysis toward melanoma detection. *International Symposium on Biomedical Imaging (ISBI)*, (International Skin Imaging Collaboration (ISIC), 2016).
19. Binder, M. et al. Epiluminescence microscopy-based classification of pigmented skin lesions using computerized image analysis and an artificial neural network. *Melanoma Res.* **8**, 261–266 (1998).
20. Menzies, S. W. et al. In *Skin Cancer and UV Radiation* (eds Altmeyer, P., Hoffmann, K., & Stucker, M.) 1064–1070 (Springer, 1997).
21. Clark, W. H., et al. Model predicting survival in stage I melanoma based on tumor progression. *J. Natl Cancer Inst.* **81**, 1893–1904 (1959).
22. Schindewell, T. et al. Classification of melanocytic lesions with color and texture analysis using digital image processing. *Anal. Quant. Cytol. Histol.* **15**, 1–11 (1993).
23. Ramakhan, K., & Shang, Y. A. Mobile automated skin lesion classification system. *230 IEEE International Conference on Tools with Artificial Intelligence (ICTA)* 138–141 (2011).
24. Ballerini, L. et al. *Color Medical Image Analysis*. (eds, Celebi, M. E. & Schaefer, G.) 63–86 (Springer, 2013).
25. Deng, J. et al. Imagenet: A large-scale hierarchical image database. *EEE Conference on Computer Vision and Pattern Recognition* 248–255 (CVPR, 2001).
26. Mnih, V. et al. Human-level control through deep reinforcement learning. *Nature* **518**, 529–533 (2015).
27. Silver, D. et al. Mastering the game of Go with deep neural networks and tree search. *Nature* **529**, 484–489 (2016).
28. Fan, S. J., & Yang, Q. A survey on transfer learning. *IEEE Trans. Knowl. Data Eng.* **22**, 1345–1359 (2010).
29. Van der Maaten, L., & Hinton, G. Visualizing data using t-SNE. *J. Mach. Learn. Res.* **9**, 2579–2605 (2008).
30. Abadi, M. et al. Tensorflow: large-scale machine learning on heterogeneous distributed systems. Preprint at <https://arxiv.org/abs/1603.04467> (2016).

روش‌ها (Methods)

مجموعه داده‌ها: (Datasets)

مجموعه داده ما از ترکیبی از مخازن دسترسی‌یاز درماتولوژی، بایگانی درموسکوپی ISIC، کتابخانه تصویری Edinbrough Dermofit و داده‌های بیمارستان استنفورد به دست آمده است. تصاویر مخازن دسترسی‌یاز آنالیز درماتولوژی توسط متخصصان پوست حاشیه‌نویسی شده‌اند، نه لزوماً از طریق بیوپسی. داده‌های بایگانی ISIC مورد استفاده صرفاً از ضایعات ملانوسیتی تشکیل شده‌اند که ثابت‌شده با بیوپسی هستند و به عنوان بدخیم یا خوشخیم حاشیه‌نویسی شده‌اند. کتابخانه Edinbrough Dermofit و داده‌های بیمارستان استنفورد ثابت‌شده با بیوپسی هستند و با نام بیماری فردی (مثلاً کراتوز اکتینیک) حاشیه‌نویسی شده‌اند. در مجموعه‌های آزمایشی ما، ضایعات ملانوسیتی شامل ملانوم‌های بدخیم - کشنده‌ترین سرطان پوست - و خال‌های (نووس) خوشخیم هستند. ضایعات اپیدرمی شامل کارسینوم‌های بدخیم سلول پایه و سنگ‌فرشی، کارسینوم‌های درون اپیتلیال، کراتوز اکتینیک پیش‌بدخیم و کراتوز سبورئیک خوشخیم هستند.

تاکسونومی: (Taxonomy)

تاکسونومی ما نشان‌دهنده ۲۰۳۲ بیماری فردی است که در یک ساختار درختی با سه گره ریشه که نمایانگر کلاس‌های کلی بیماری هستند، مرتب شده‌اند: (۱) ضایعات خوشخیم، (۲) ضایعات بدخیم، و (۳) ضایعات غیرنئوپلاستیک) شکل

2. b) این تاکسونومی توسط متخصصان پوست با استفاده از یک رویکرد از پایین به بالا استخراج شد: بیماری‌های فردی، که به عنوان گره‌های برگ مقداردهی اولیه شدند، بر اساس شباهت بالینی و بصری ادغام شدند تا زمانی که کل ساختار متصل شد. این جنبه از تاکسونومی در تولید کلاس‌های آموزشی که هم برای طبقه‌بندی یادگیری ماشین مناسب هستند و هم مرتبط با پزشکی هستند، مفید است. گره‌های ریشه در اولین استراتژی اعتبارسنجی استفاده می‌شوند و نمایانگر تقسیم‌بندی کلی‌ترین هستند. فرزندان گره‌های ریشه (مثلاً ضایعات ملانوسیتی بدخیم) در دومین استراتژی اعتبارسنجی استفاده می‌شوند و نمایانگر کلاس‌های بیماری هستند که برنامه‌های درمانی بالینی مشابهی دارند.

آماده‌سازی داده: (Data preparation)

تصاویر محو و تصاویر با فاصله دور از مجموعه‌های آزمایش و اعتبارسنجی حذف شدند، اما همچنان در آموزش استفاده شدند. مجموعه داده ما شامل مجموعه‌هایی از تصاویر مربوط به یک ضایعه واحد اما از چندین زاویه دید، یا چندین تصویر از ضایعات مشابه روی یک فرد است. در حالی که این داده‌های آموزشی مفیدی هستند، مراقبت گسترده‌ای انجام شد تا اطمینان حاصل شود که این مجموعه‌ها بین مجموعه‌های آموزش و اعتبارسنجی تقسیم نشده‌اند. با استفاده از ابر داده EXIF تصویر، اطلاعات خاص مخزن و بازایی تصویر نزدیک‌ترین همسایه با ویژگی‌های CNN، یک گراف بدون جهت ایجاد کردیم که هر جفت تصویری که مشابه تشخیص داده می‌شدند را به هم متصل می‌کرد. اجزای متصل این گراف اجازه نداشتند که تقسیم آموزش/اعتبارسنجی را پوشش دهند و به طور تصادفی به آموزش یا اعتبارسنجی اختصاص داده می‌شدند. مجموعه‌های آزمایشی همگی از مخازن مستقل و باکیفیت تصاویر ثابت شده با بیوپسی - بیمارستان استنفورد، کتابخانه تصویری Dermofit دانشگاه ادینبرو و بایگانی درموسکوپي - ISIC می‌آمدند. هیچ همپوشانی (مثلاً همان ضایعه، چندین زاویه دید) بین مجموعه‌های آزمایش و داده‌های آموزش/اعتبارسنجی وجود ندارد.

انتخاب نمونه: (Sample selection)

آزمایش‌های اپیدرمی، ملانوسیتی و ملانوسیتی-درموسکوپي شکل 3a به ترتیب از ۱۳۵ (۶۵ بدخیم، ۷۵ خوش‌خیم)، ۱۳۰ (۳۳ بدخیم، ۹۷ خوش‌خیم) و ۱۱۱ (۷۱ بدخیم، ۴۰ خوش‌خیم) تصویر استفاده کردند. همتایان آن‌ها در شکل 3b به ترتیب از ۷۰۷ (۴۵۰ بدخیم، ۲۵۷ خوش‌خیم)، ۲۲۵ (۵۸ بدخیم، ۱۶۷ خوش‌خیم) و ۱۰۱۰ (۶۸ بدخیم، ۹۲۲ خوش‌خیم) تصویر استفاده کردند. تعداد تصاویر استفاده شده برای شکل 3b بر اساس در دسترس بودن داده‌های برچسب‌گذاری شده با بیوپسی بود (یعنی ضایعات ملانوسیتی بدخیم در مقایسه با ضایعات ملانوسیتی خوش‌خیم بسیار نادر هستند). این اعداد توسط استانداردهای چالش بینایی کامپیوتری ILSVRC⁶ توجیه آماری شده‌اند، که دارای ۵۰۰۰۰ تصویر در هر کلاس برای مجموعه‌های اعتبارسنجی و آزمایش است. برای شکل 3a، ۱۴۰ تصویر به طور تصادفی از هر مجموعه شکل 3b انتخاب شد و یک متخصص پوست آزمایش نشده (که از تشخیص بی‌خبر بود) هر تصویر با وضوح ناکافی را حذف کرد (اگرچه شبکه ورودی‌های تصویری ۲۹۹ × ۲۹۹ پیکسل را می‌پذیرد، متخصصان پوست برای وضوح بیشتر به تصاویر بزرگتر نیاز داشتند).

الگوریتم تقسیم‌بندی بیماری: (Disease partitioning algorithm)

الگوریتمی که بیماری‌های فردی را به کلاس‌های آموزشی تقسیم می‌کند به طور گسترده‌تری در جدول داده‌های گسترده ۱ ترسیم شده است. این یک الگوریتم بازگشتی است، که برای بهره‌برداری از تاکسونومی برای تولید کلاس‌های آموزشی طراحی شده است که بیماری‌های فردی آن‌ها از نظر بالینی و بصری مشابه هستند. الگوریتم میانگین اندازه کلاس آموزشی تولیدشده را کمی کمتر از تنها ابرپارامتر آن، maxClassSize، نگه می‌دارد. در کنار هم، این اجزا تعادلی برقرار می‌کنند بین (۱) تولید کلاس‌های آموزشی که بیش از حد ظریف هستند و داده کافی برای یادگیری مناسب ندارند؛ (۲) تولید کلاس‌های آموزشی که بیش از حد درشت هستند، داده فراوانی دارند و الگوریتم را به سمت آن‌ها سوگیری می‌کنند. با maxClassSize = ۱۰۰۰ این الگوریتم یک تقسیم‌بندی بیماری از ۷۵۷ کلاس به دست می‌دهد. همه کلاس‌های آموزشی زیرشاخه‌ی کلاس‌های استنتاج هستند.

الگوریتم آموزش: (Training algorithm)

ما از معماری CNN اینسپشن v3 گوگل که پیش‌آموزش دیده شده تا به دقت ۹۳.۳۳٪ در پنج رده برتر روی ۱۰۰۰ کلاس شیء (۱.۲۸ میلیون تصویر) چالش ImageNet 2014 پیروی از منبع ۹ استفاده می‌کنیم. سپس لایه طبقه‌بندی نهایی را از شبکه حذف کرده و آن را با مجموعه داده خود مجدداً آموزش می‌دهیم، پارامترها را در تمام لایه‌ها تنظیم

دقیق می‌کنیم. در طول آموزش هر تصویر را به 299×299 پیکسل تغییر اندازه می‌دهیم تا با ابعاد اصلی معماری شبکه اینسپشن v3 سازگار شده و از ویژگی‌های تصویر طبیعی آموخته‌شده توسط شبکه پیش‌آموزش دیده ImageNet بهره ببریم. این روش، که به عنوان یادگیری انتقالی شناخته می‌شود، با توجه به میزان داده موجود بهینه است.

CNN ما با استفاده از انتشار معکوس آموزش دیده است. تمام لایه‌های شبکه با استفاده از نرخ یادگیری جهانی یکسان ۰.۰۰۱ و یک فاکتور تضعیف ۱۶ هر ۳۰ دوره، تنظیم دقیق می‌شوند. ما از RMSProp با تضعیف ۰.۹، ممنتوم ۰.۹ و ایسیلون ۰.۱ استفاده می‌کنیم. ما از چارچوب یادگیری عمیق TensorFlow¹⁰ گوگل برای آموزش، اعتبارسنجی و آزمایش شبکه خود استفاده می‌کنیم. در طول آموزش، تصاویر با ضریب ۷۲۰ افزایش می‌یابند. هر تصویر به طور تصادفی بین ۰ تا ۳۵۹ درجه چرخانده می‌شود. سپس بزرگترین مستطیل محاطی عمودی از تصویر برش داده می‌شود و با احتمال ۰.۵ به صورت عمودی معکوس می‌شود.

الگوریتم استنتاج: (Inference algorithm)

ما از این قرارداد پیروی می‌کنیم که هر گره شامل فرزندانش است. هر کلاس آموزشی توسط یک گره در تاکسونومی، و متعاقباً، تمام زیرشاخه‌هایش نمایش داده می‌شود. هر کلاس استنتاج یک گره است که به عنوان زیرشاخه‌هایش مجموعه خاصی از گره‌های آموزشی را دارد. یک مثال گویا در شکل داده‌های گسترده ۱ نشان داده شده است، با گره‌های قرمز به عنوان کلاس‌های استنتاج و گره‌های سبز به عنوان کلاس‌های آموزشی. با توجه به یک تصویر ورودی، CNN یک توزیع احتمال روی گره‌های آموزشی خروجی می‌دهد. احتمالات روی تاکسونومی به صورت زیر محاسبه می‌شوند:

$$P(u) = \sum_{v \in C(u)} P(v)$$

که در آن u هر گرهی است، $P(u)$ احتمال u است، و $C(u)$ گره‌های فرزند u هستند. بنابراین، برای بازیابی احتمال هر گره استنتاجی، کافی است احتمالات گره‌های آموزشی زیرشاخه آن را جمع کنیم. توجه داشته باشید که در استراتژی‌های اعتبارسنجی همه کلاس‌های آموزشی در کلاس‌های استنتاج جمع می‌شوند. اما در موارد طبقه‌بندی دوگانه، تصاویر مورد بحث شناخته شده است که یا ملانوسیتی هستند یا اپیدرمی و بنابراین ما تنها از کلاس‌های آموزشی استفاده می‌کنیم که زیرشاخه کلاس‌های ملانوسیتی یا اپیدرمی هستند.

ماتریس‌های درهم‌ریختگی: (Confusion matrices)

شکل داده‌های گسترده ۲ ماتریس درهم‌ریختگی روش ما را روی نه کلاس استراتژی اعتبارسنجی دوم) جدول داده‌های گسترده 2) در مقایسه با دو متخصص پوست آزمایش‌شده نشان می‌دهد. این شباهت در اشتباه طبقه‌بندی بین CNN و متخصصان انسانی را نشان می‌دهد. عنصر (i, j) هر ماتریس درهم‌ریختگی نمایانگر احتمال تجربی پیش‌بینی کلاس j با توجه به اینکه کلاس i صحیح است. کلاس‌های ۷ و ۸ - ضایعات ملانوسیتی خوش‌خیم و بدخیم - اغلب با یکدیگر اشتباه گرفته می‌شوند. بسیاری از تصاویر به اشتباه به عنوان کلاس ۶، کلاس التهابی، طبقه‌بندی می‌شوند که به دلیل تغییرپذیری بالای بیماری‌ها در این دسته است. توجه کنید که چگونه تومورهای درمی بدخیم به راحتی توسط هر دو CNN و متخصصان پوست با کلاس‌های دیگر اشتباه گرفته می‌شوند. این تومورها اساساً ندول‌هایی زیر پوست هستند که تشخیص بصری آن‌ها چالش‌برانگیز است.

نقشه‌های برجستگی: (Saliency maps)

برای تجسم پیکسل‌هایی که شبکه برای پیش‌بینی خود روی آن‌ها متمرکز می‌شود، ما نقشه‌های برجستگی را تولید می‌کنیم، که در شکل داده‌های گسترده ۳ برای تصاویر نمونه از نه کلاس جدول داده‌های گسترده 2 نشان داده شده است. انتشار معکوس کاربرد قاعده زنجیره‌ای حسابان برای محاسبه گرادیان‌های تابع هزینه برای تمام وزن‌ها در شبکه است. گرادیان تابع هزینه همچنین می‌تواند به لایه داده ورودی انتشار معکوس یابد. با گرفتن نرم L1 این گرادیان تابع هزینه لایه ورودی در سرتاسر کانال‌های RGB، نقشه حرارتی حاصل به طور شهودی اهمیت هر پیکسل را برای

تشخیص نشان می‌دهد. همانطور که دیده می‌شود، شبکه بیشتر توجه خود را بر روی خود ضایعات متمرکز می‌کند و پس‌زمینه و پوست سالم را نادیده می‌گیرد.

منحنی‌های حساسیت-ویژگی با سوالات مختلف (Sensitivity-specificity curves with different questions):

در متن اصلی ما حساسیت و ویژگی CNN خود را با حداقل ۲۱ متخصص پوست در سه وظیفه تشخیصی شکل ۳ مقایسه می‌کنیم. برای این تحلیل از هر متخصص پوست پرسیده شد که آیا ضایعه را بیوپسی/درمان می‌کنند یا به بیمار اطمینان خاطر می‌دهند. این انتخاب سؤال منعکس‌کننده وظیفه واقعی درون کلینیکی است که متخصصان پوست باید انجام دهند - تصمیم‌گیری برای ادامه یا عدم ادامه تحلیل پزشکی یک ضایعه. یک سؤال مشابه برای پرسیدن از متخصص پوست، اگر چه کمتر مرتبط با بالین است، این است که آیا فکر می‌کنند یک ضایعه بدخیم است یا خوش‌خیم. نتایج این تحلیل در شکل داده‌های گسترده ۴ نشان داده شده است. همانند شکل ۳، CNN هم‌تراز با عملکرد متخصصان پوست است و از میانگین آن‌ها بهتر عمل می‌کند. در آزمایش ضایعات اپیدرمی، CNN دقیقاً بالاتر از یک انحراف معیار از میانگین متخصصان پوست است و در هر دو آزمایش ضایعات ملانوسیتی، CNN دقیقاً کمتر از یک انحراف معیار از میانگین متخصصان پوست است.

استفاده از سوژه‌های انسانی: (Use of human subjects)

تمام سوژه‌های انسانی متخصصان پوست دارای مورد تخصصی بودند که آزمون‌های ما را با رضایت آگاهانه انجام دادند. این مطالعه توسط هیئت بازبینی مؤسسه استنفورد، تحت شماره ثبت کارآزمایی ۳۶۰۵۰ تأیید شد.


بیانیه در دسترس بودن داده: (Data availability statement)

مجموعه‌های آزمایش پزشکی که یافته‌های این مطالعه را پشتیبانی می‌کنند، از بایگانی-ISIC ([https://isic-](https://isic-archive.com/) archive.com/) و کتابخانه Edinburgh Dermofit

(<https://licensing.eri.ed.ac.uk/i/software/dermofit-image-library.html>) در دسترس هستند.


محدودیتی برای در دسترس بودن داده‌های آموزش/اعتبارسنجی پزشکی اعمال می‌شود، که با اجازه برای مطالعه فعلی استفاده شدند و بنابراین به طور عمومی در دسترس نیستند. برخی داده‌ها ممکن است با درخواست معقول و با اجازه بیمارستان استنفورد در اختیار نویسندگان قرار گیرند.

© 2017 Macmillan Publishers Limited, بخشی از Springer Nature. تمامی حقوق محفوظ است.



Extended Data Figure 2 | Confusion matrix comparison between CNN and dermatologists. Confusion matrices for the CNN and both dermatologists for the nine-way classification task of the second validation strategy reveal similarities in misclassification between human experts and the CNN. Element (i, j) of each confusion matrix represents the empirical probability of predicting class j given that the ground truth was class i , with i and j referencing classes from Extended Data Table 2d. Note that both the CNN and the dermatologists noticeably confuse benign and malignant melanocytic lesions—classes 7 and 8—with each other, with


dermatologists erring on the side of predicting malignant. The distribution across column 6—inflammatory conditions—is pronounced in all three plots, demonstrating that many lesions are easily confused with this class. The distribution across row 2 in all three plots shows the difficulty of classifying malignant dermal tumours, which appear as little more than cutaneous nodules under the skin. The dermatologist matrices are each computed using the 180 images from the nine-way validation set. The CNN matrix is computed using a random sample of 684 images (equally distributed across the nine classes) from the validation set.




Extended Data Figure 3 | Saliency maps for nine example images from the second validation strategy. a–i, Saliency maps for example images from each of the nine clinical disease classes of the second validation strategy reveal the pixels that most influence a CNN's prediction. Saliency maps show the pixel gradients with respect to the CNN's loss function. Darker pixels represent those with more influence. We see clear correlation between the lesions themselves and the saliency maps. Conditions with a single lesion (a–f) tend to exhibit tight saliency maps centred around the lesion. Conditions with spreading lesions (g–i) exhibit saliency maps that similarly occupy multiple points of interest in the images. a, Malignant melanocytic lesion (source image: <https://www.dermquest.com/imagelibrary/large/020114HB.JPG>). b, Malignant epidermal

lesion (source image: <https://www.dermquest.com/imagelibrary/large/001883HB.JPG>). c, Malignant dermal lesion (source image: <https://www.dermquest.com/imagelibrary/large/019328HB.JPG>). d, Benign melanocytic lesion (source image: <https://www.dermquest.com/imagelibrary/large/010137HB.JPG>). e, Benign epidermal lesion (source image: <https://www.dermquest.com/imagelibrary/large/046347HB.JPG>). f, Benign dermal lesion (source image: <https://www.dermquest.com/imagelibrary/large/021553HB.JPG>). g, Inflammatory condition (source image: <https://www.dermquest.com/imagelibrary/large/030028HB.JPG>). h, Genodermatosis (source image: <https://www.dermquest.com/imagelibrary/large/030705VB.JPG>). i, Cutaneous lymphoma (source image: <https://www.dermquest.com/imagelibrary/large/030540VB.JPG>).

a. Deep learning outperforms the average dermatologist at skin cancer classification using photographic and dermoscopic images.



b. Deep learning exhibits reliable cancer classification when tested on a larger dataset.



Extended Data Figure 4 | Extension of Figure 3 with a different dermatological question. a. Identical plots and results as shown in Fig. 3a, except that dermatologists were asked if a lesion appeared to be malignant or benign. This is a somewhat unnatural question to ask, in the clinic, the

only actionable decision is whether or not to biopsy or treat a lesion. The blue curves for the CNN are identical to Fig. 3. b, Figure 3b reprinted for visual comparison to a.

Algorithm 1 Disease Partitioning Algorithm

```

1: Inputs
2:   taxonomy (tree): the disease taxonomy
3:   maxClassSize (int): maximum data points in a class
4: Output
5:   partition (list of sets): partition of the diseases into classes
6:
7: procedure DESCENDANTS(node)
8:   return {node}  $\cup$  {DESCENDANTS(child) for child in node.children}
9:
10: procedure NUMIMAGES(nodes)
11:   return SUM(LENGTH(node.images) for node in nodes)
12:
13: procedure PARTITIONDISEASES(node)
14:   class  $\leftarrow$  DESCENDANTS(node)
15:   if NUMIMAGES(class) < maxClassSize then
16:     append class to partition
17:   else
18:     for child in node.children do
19:       PARTITIONDISEASES(child)
20:
21: partition  $\leftarrow$  [ ]
22: PARTITIONDISEASES(taxonomy.root)
23: return partition

```

This algorithm uses the taxonomy to partition the diseases into fine-grained training classes. We find that training on these finer classes improves the classification accuracy of coarser inference classes. The algorithm begins with the top node and recursively descends the taxonomy (line 19), turning nodes into training classes if the amount of data contained in them (with the convention that nodes contain their children) does not exceed a specified threshold (line 15). During partitioning, the recursive property maintains the taxonomy structure, and consequently, the clinical similarity between different diseases grouped into the same training class. The data restriction (and the fact that training data are fairly evenly distributed amongst the leaf nodes) forces the average class size to be slightly less than *maxClassSize*. Together these components generate training classes that leverage the fine-grained information contained in the taxonomy structure while striking a balance between generating classes that are overly fine-grained and do not have sufficient data to be learned properly, and classes that are too coarse, too data abundant and that prevent the algorithm from properly learning less data-abundant classes. With *maxClassSize* = 1,000 this algorithm yields 757 training classes.

Extended Data Table 2 | General validation results

a. Classifier		b. Classifier	
Three-way accuracy		Nine-way accuracy	
Dermatologist 1	65.6%	Dermatologist 1	53.3%
Dermatologist 2	66.0%	Dermatologist 2	55.0%
CNN	69.4 ± 0.8%	CNN	48.9 ± 1.9%
CNN - PA	72.1 ± 0.9%	CNN - PA	55.4 ± 1.7%

c. Disease classes: three-way classification		d. Disease classes: nine-way classification	
0. Benign single lesions 1. Malignant single lesions 2. Non-neoplastic lesions		0. Cutaneous lymphoma and lymphoid infiltrates 1. Benign dermal tumors, cysts, sinuses 2. Malignant dermal tumor 3. Benign epidermal tumors, hamartomas, milia, and growths 4. Malignant and premalignant epidermal tumors 5. Genodermatoses and supernumerary growths 6. Inflammatory conditions 7. Benign melanocytic lesions 8. Malignant Melanoma	

Here we show ninefold cross-validation classification accuracy with 127,463 images organized in two different strategies. In each fold, a different ninth of the dataset is used for validation, and the rest is used for training. Reported values are the mean and standard deviation of the validation accuracy across all $n = 9$ folds. These images are labelled by dermatologists, not necessarily through biopsy; meaning that this metric is not as rigorous as one with biopsy-proven images. Thus we only compare to two dermatologists as a means to validate that the algorithm is learning relevant information. **a.** Three-way classification accuracy comparison between algorithms and dermatologists. The dermatologists are tested on 180 random images from the validation set—60 per class. The three classes used are first-level nodes of our taxonomy. A CNN trained directly on these three classes also achieves inferior performance to one trained with our partitioning algorithm (PA). **b.** Nine-way classification accuracy comparison between algorithms and dermatologists. The dermatologists are tested on 180 random images from the validation set—20 per class. The nine classes used are the second-level nodes of our taxonomy. A CNN trained directly on these nine classes achieves inferior performance to one trained with our partitioning algorithm. **c.** Disease classes used for the three-way classification represent highly general disease classes. **d.** Disease classes used for nine-way classification represent groups of diseases that have similar aetiologies.

تصحیح (Corrigendum)

شناسه دیجیتالی:10.1038/nature22985 (doi):

تصحیح: طبقه‌بندی سرطان پوست در سطح متخصص پوست با استفاده از شبکه‌های عصبی عمیق

آندره استوا، برت کوپرل، رابرتو آ. ئووا، جاستین کو، سوزان ام. سوئتر، هلن ام. بلائو و سباستین ثرون

نیچر ۵۴۲، ۱۱۵–۱۱۸ (۲۰۱۷)؛ شناسه دیجیتالی:10.1038/nature21056

در بخش تشکرهای این مقاله، جمله: "این مطالعه توسط بنیاد بکستر، کمک‌های مالی مؤسسه پزشکی باززایی کالیفرنیا (CIRM) با شماره‌های TT3-05501 و RB5-07469 و کمک‌های مالی مؤسسه ملی سلامت (NIH) آمریکا با شماره‌های AG044815، AG009521، NS089533، AR063963 (و AG020961 به H.M.B. حمایت شد." باید به این صورت خوانده می‌شد: "این مطالعه توسط حمایت مالی از بنیاد بکستر به H.M.B. حمایت شد." علاوه بر این، آخرین خط بخش تشکرها باید به این صورت خوانده می‌شد: "علاوه بر این، این کار توسط یک جایزه علوم انتقالی بالینی و ترجمه‌ای مرکز ملی پیشبرد علوم انتقالی مؤسسه ملی سلامت (NIH) آمریکا (UL1 TR001085) حمایت شد. محتوا صرفاً مسئولیت نویسندگان است و لزوماً نمایانگر دیدگاه‌های رسمی NIH نیست." مقاله اصلی به صورت آنلاین تصحیح شده است.

۶۸۶ | Nature | جلد ۵۴۶ | ۲۹ ژوئن ۲۰۱۷

© 2017 Macmillan Publishers Limited، بخشی از Springer Nature. تمامی حقوق محفوظ است.