

تعامل انسان و هوش مصنوعی در تشخیص سرطان پوست: یک مرور نظاممند و متاآنالیز

ایزابل کراکوفسکی^{1,2,3,8}، جی یانگ کیم^{1,3,8}، ژوران کای^{1,3}، روکسانا دانیشجو¹، جان لاپینز⁵، هانا اریکسون^{2,6}، آناستازیا لیوکو⁷ و النی لینوس^{1,3}

توسعه ابزارهای تشخیصی سرطان پوست مبتنی بر هوش مصنوعی به سرعت در حال افزایش است و به احتمال زیاد به زودی به طور گسترده در کاربردهای بالینی پیاده‌سازی خواهد شد. با این که عملکرد این الگوریتم‌ها از نظر تئوری امیدوارکننده است، شواهد محدودی در مورد تأثیر کمک هوش مصنوعی بر تصمیمات تشخیصی انسان وجود دارد. بنابراین، هدف این مرور نظاممند و متاآنالیز، مطالعه اثر کمک هوش مصنوعی بر دقت تشخیص سرطان پوست بود. ما پایگاه‌های داده PubMed، Embase، IEE Xplore، Scopus و مقالات کنفرانس‌ها را از تاریخ 1 ژانویه 2017 تا 8 نوامبر 2022 جستجو کردیم. مطالعاتی را که عملکرد متخصصان بالینی در تشخیص حداقل یک سرطان پوست را با و بدون کمک هوش مصنوعی مبتنی بر یادگیری عمیق مقایسه می‌کردند، وارد کردیم. برآوردهای خلاصه‌شده حساسیت و ویژگی دقت تشخیصی با در مقابل بدون کمک هوش مصنوعی با استفاده از یک مدل اثرات تصادفی دو متغیره محاسبه شد. 2983 مطالعه را شناسایی کردیم که از این میان، ده مطالعه واجد شرایط برای متاآنالیز بودند. برای متخصصان بالینی بدون کمک هوش مصنوعی، حساسیت تجمیع‌شده 74.8٪ (95٪ فاصله اطمینان 68.6–80.1) و ویژگی 81.5٪ (95٪ فاصله اطمینان 73.9–87.3) بود. برای متخصصان بالینی کمک‌شده با هوش مصنوعی، حساسیت کلی 81.1٪ (95٪ فاصله اطمینان 74.4–86.5) و ویژگی 86.1٪ (95٪ فاصله اطمینان 79.2–90.9) بود. هوش مصنوعی در تحلیل‌های زیرگروهی برای متخصصان پزشکی در تمام سطوح تجربه مفید بود، با بیشترین بهبود در میان غیرمتخصصان پوست. هیچ سوگیری انتشار شناسایی نشد و تحلیل حساسیت نشان داد که یافته‌ها قوی هستند. هوش مصنوعی در دست متخصصان بالینی پتانسیل بهبود دقت تشخیصی در تشخیص سرطان پوست را دارد. با توجه به این که اکثر مطالعات در محیط‌های آزمایشی انجام شده‌اند، مطالعات آینده را تشویق می‌کنیم تا این مزایای بالقوه را در محیط‌های واقعی بیشتر بررسی کنند.

در نتیجه افزایش در دسترس بودن داده و قدرت محاسباتی، الگوریتم‌های هوش مصنوعی به سطحی از پیچیدگی رسیده‌اند که به آن‌ها امکان می‌دهد وظایف پیچیده‌ای را که قبلاً تنها توسط انسان انجام می‌شد، بر عهده بگیرند¹. چندین الگوریتم هوش مصنوعی اکنون توسط سازمان غذا و داروی ایالات متحده (FDA) برای مصارف پزشکی تأیید شده‌اند^{2,3}. اگرچه در حال حاضر هیچ برنامه کاربردی هوش مصنوعی مبتنی بر تصویر در پوست‌شناسی وجود ندارد که تأییدیه FDA داشته باشد، چندین مورد در حال توسعه هستند⁴.

تشخیص سرطان پوست بسیار به تفسیر الگوهای بصری متکی است و آن را به وظیفه‌ای پیچیده تبدیل می‌کند که نیازمند آموزش گسترده در پوست‌شناسی و درماتوسکوپی است^{5,6}. با این حال، نشان داده شده که الگوریتم‌های هوش مصنوعی قادر به تشخیص دقیق سرطان‌های پوست هستند، حتی در وظایف طبقه‌بندی تصویر در محیط‌های محدود از متخصصان پوست با تجربه نیز بهتر عمل می‌کنند^{7,8}. با این حال، این الگوریتم‌ها می‌توانند نسبت به تغییرات توزیع داده حساس باشند. بنابراین، مشارکت انسان و هوش مصنوعی می‌تواند بهبود عملکردی فراهم کند که بر محدودیت‌های هر یک از متخصصان بالینی یا هوش مصنوعی به تنهایی غلبه کند. قابل توجه است که چاندل و همکاران در مقاله سال 2020 خود نشان دادند که دقت متخصصان بالینی پشتیبانی‌شده توسط الگوریتم‌های هوش مصنوعی از دقت هر یک از متخصصان بالینی یا الگوریتم‌های هوش مصنوعی که به طور جداگانه کار می‌کنند، فراتر رفته است⁹. این رویکرد مشارکت متخصص بالینی و هوش مصنوعی، با توجه به نگرانی‌های اخلاقی و قانونی تشخیص خودکار به تنهایی، محتمل‌ترین کاربرد بالینی هوش مصنوعی در پوست‌شناسی در نظر گرفته می‌شود. بنابراین، نیاز فوری برای درک بهتر این که استفاده از هوش مصنوعی توسط متخصصان بالینی چگونه بر تصمیم‌گیری تأثیر می‌گذارد، وجود دارد¹. هدف این مطالعه ارزیابی دقت تشخیصی متخصصان بالینی با در مقابل بدون کمک هوش مصنوعی با استفاده از یک مرور نظاممند و متاآنالیز از ادبیات موجود بود.

نتایج

جستجو و غربالگری ادبیات


برای این مرور نظاممند و متاآنالیز، در ابتدا 2983 رکورد بازبازی شد که از این تعداد، 1972 چکیده پس از حذف خودکار تکراری‌ها توسط Covidence غربال شدند (شکل 1). از آنجا که 1936 مقاله نامربوط در نظر گرفته شد و حذف گردید،

متن کامل 36 مقاله بررسی شد. در مجموع 12 مطالعه در مرور نظام‌مند گنجانده شد [0,12-22] و ده مطالعه در متاآنالیز گنجانده شد [0,12-15,17,19-22]، در حالی که اطلاعات لازم برای ایجاد جداول احتمالی متخصصان پزشکی کمک‌شده و غیرکمک‌شده با هوش مصنوعی در دو مطالعه در دسترس نبود [4,18].

ویژگی‌های مطالعه

جداول 1 و 2 ویژگی‌های مطالعات وارد شده را ارائه می‌دهند. نیمی از مطالعات در آسیا (50٪، کره جنوبی=5، چین=1) و نیم دیگر در آمریکای شمالی/جنوبی (25٪، ایالات متحده=1، آرژانتین=1، شیلی=1) و اروپا (25٪، اتریش=1، آلمان=1، سوئیس=1) انجام شده بود. مطالعات بیشتری در محیط‌های آزمایشی (67٪، $n=8$ نسبت به محیط‌های بالینی 33٪، $n=4$) انجام شد. یک چهارم مطالعات تنها شامل متخصصان پوست (25٪، $n=3$ بودند، بیش از نیمی 58٪، $n=7$ ترکیبی از متخصصان پوست/شناسی (مانند متخصص پوست و دستیاران پوست) و متخصصان پزشکی غیرپوست (مانند پزشکان مراقبت اولیه، پرستاران حرفه‌ای، دانشجویان پزشکی) را شامل می‌شدند و در میان این‌ها، دو مطالعه شامل افراد عادی بود، اما این داده برای متاآنالیز گنجانده نشد. در دو مطالعه (17٪)، تنها متخصصان پزشکی غیرپوست گنجانده شدند. میانۀ تعداد شرکت‌کنندگان مطالعه 18.5 بود که از 7 تا 302 متغیر بود.

Fig. 1 | Study selection. Flow diagram of the study selection process.



اطلاعات بالینی علاوه بر تصاویر یا ویزیت‌های بیمارستانی در نیمی از مطالعات (50٪، $n=6$) در اختیار شرکت‌کنندگان مطالعه قرار گرفت. برای تشخیص، تصاویر بالینی سرپایی بیشترین ارائه (42٪، $n=5$) داشت، به دنبال آن تصاویر درماتوسکوپی (33٪، $n=4$) و ویزیت‌های بیمارستانی (25٪، $n=3$)، و وظیفه تشخیصی یا انتخاب محتمل‌ترین تشخیص (58٪، $n=7$) رتبه‌بندی ضایعه به عنوان بدخیم در مقابل خوش‌خیم (42٪، $n=5$) بود. اکثر مطالعات (75٪، $n=9$) از طرح جفتی استفاده کردند که در آن همان خواننده ابتدا بدون، سپس با کمک هوش مصنوعی همان مورد را تشخیص می‌داد، در حالی که دو مطالعه تصاویر متفاوتی بین دو وظیفه ارائه کردند. یک طرح متقاطع کامل (یعنی تمام خوانندگان تمام موارد را در هر دو روش تشخیص دهند) در چهار مطالعه انجام شد. یک مطالعه تنها تشخیص با پشتیبانی هوش مصنوعی را گزارش کرد، بنابراین امکان تحلیل اثر هوش مصنوعی را نمی‌داد¹. مطالعات شامل یک استاندارد مرجع بودند که ترکیبات مختلفی از هیستوپاتولوژی، تشخیص پانلی از متخصصان پوست یا پزشک معالج، از پرونده‌های پزشکی، پیگیری بالینی یا میکروسکوپ کانفوکال درون‌تن بودند (75٪، $n=9$) یا تشخیص هیستوپاتولوژی یک روی تمام تصاویر (17٪، $n=2$). یک مطالعه یا هیستوپاتولوژی یا توافق شرکت‌کننده مطالعه با دو ابزار هوش مصنوعی که مورد مطالعه قرار گرفته بودند را به عنوان استاندارد مرجع در نظر گرفت¹. اکثر الگوریتم‌های هوش مصنوعی توضیحی برای خروجی‌های خود یا ارائه فراتر از تشخیص‌های برتر اول یا سوم به همراه احتمالات مربوطه یا نمره بدخیمی دودویی ارائه نمی‌دادند. بازیابی

تصویر مبتنی بر محتوا (CBIR) تنها روش قابل توضیح بود که استفاده شد، یعنی در دو مطالعه (17٪) و مطالعه چاندل و همکاران¹ تنها مطالعه‌ای بود که به اثرات نمایش‌های مختلف خروجی هوش مصنوعی بر عملکرد تشخیصی پزشکان پرداخت. تعریف وضعیت هدف در مطالعات متفاوت بود، اما همه مطالعات حداقل یک سرطان پوست را در میان تشخیص‌های اشتراقی شامل می‌شدند. خلاصه ارزیابی‌های کیفیت روش‌شناسی را می‌توان در جدول تکمیلی 1 یافت. اگرچه کاپا پایین بود ($k = 0.33$)، آزمون تقارن باکر¹ معنی‌دار نبود، بنابراین دو ارزیاب تمایل یکسانی برای انتخاب دسته‌ها در نظر گرفته شدند. هر سه ارزیاب با ارزیابی‌های کیفیت نهایی موافق بودند.

شکل 1 | انتخاب مطالعه. نمودار جریان فرآیند انتخاب مطالعه.

Table 1 (continued) | Study characteristics of the 12 included studies

Source	Target condition	Setting and design	Participants	Patients	Reference standard	Classification task	No. of cases/participant
Lucius et al. ¹⁸	Pigmented skin lesions (7 categories: melanocytic nevi, vascular skin lesions, benign keratosis, DF, intraepithelial carcinomas, BCC, and MM)	Reader study, Argentina	19 primary care physicians	70 dermoscopic images from the HAM 10,000 dataset. Clinical data: N/A	Histopathology, biology (>1.5 years of sequential dermoscopic imaging without changes), expert consensus and in vivo confocal images	Classification of 35 dermoscopic images without algorithmic assistance, then 35 new images with algorithmic assistance. Time constraint: 45 seconds.	70
Maron et al. ²²	MM vs. nevus	Reader study, Germany	12 dermatologists from 9 university hospitals	1200 dermoscopic images from the ISIC archive. No clinical data.	Histopathology on all images	First assessment without AI assistance. Next, the same images with dermatologist's old assessment + AI assistance and possibility to modify diagnosis. Diagnosis, image quality rating and confidence was recorded. Participants were informed of the classifier's performance.	100 (12 individual test sets)
Muñoz-López et al. ^{1,14}	Skin lesions (5 categories: inflammatory, infectious, neoplastic, alopecia, other) with 13 subcategories.	Prospective clinical study, Chile	Unknown number of dermatologists participated in the telemedicine study. 9 medical professionals participated in a reader study diagnosing the lesions without the help of AI	281 consecutive patients submitting clinical images of 340 skin lesions (taken by the patient) and sharing clinical information during telemedicine visit.	Histopathology or clinical diagnosis, otherwise consensus of 6 dermatologists	Dermatologist reviewed clinical images + interviewed patients on a video call. Recorded diagnosis + treatment plan + uploaded image to AI tool (could impact the outcome). Recorded if AI was considered helpful + if it changed initial diagnosis (no before and after diagnosis was recorded).	N/A
Tscharndl et al. ^{1,15}	Pigmented skin lesions (7 categories: MM, BCC, AK + intraepithelial carcinomas, nevi, benign keratinocytic lesions, DF and vascular lesions)	Reader study, Austria (study participants from 41 countries)	302 medical professionals (169 dermatologists 77 dermatology residents, 39 primary care physicians, 4 medical specialists, 1 medical student, 4 non-medical, 7 nurse practitioners, 2 residents) from 41 countries	1412 of 1511 Dermoscopic images from the ISIC 2018 challenge without clinical data.	Histopathology, biology (>1.5 years of sequential dermoscopic imaging without changes), expert consensus, or in vivo confocal images	Classification of batches of 28 dermoscopic images first without, then with one type of AI support, or with crowd-based decision support. Possibility to modify diagnosis. Time used as a surrogate for confidence.	One test = 28 images, each rater could perform up to five tests

BCC basal cell carcinoma, SCC squamous cell carcinoma, DF dermatofibroma, SK seborrheic keratosis, AK actinic keratosis, MM malignant melanoma, MMs melanoma in situ, LP lichen planus, N/A not applicable, HAM 10,000: Human Against Machine with 10,000 training images dataset, ISIC International Skin Imaging Collaboration, SNU Seoul National University Bundang Hospital, Inje University Sanggye Paik Hospital, and Hallym University Dongtan Hospital, clinical diagnosis: the diagnosis made by the treating dermatologist

*More than one experiment was performed in the study, but only the experiment that was included in the meta-analysis is reported in the table.

¹Only histologically confirmed cases were included in the meta-analysis.

²The effect of the AI assistance was not evaluated with a before and after diagnosis, only self-reported.

Table 2 | Characteristics of the algorithms and data used in the included studies

Source	Output of algorithm	Algorithm	No. images for training	Data source	External validation?	Private sector funding?
Ba et al. ²¹	Top 3 diagnoses	AI skinreader (EfficientNet-B3)	25,773 images training and validation (80/20 split)	Chinese PLA General Hospital & Medical School	No	No
Cho et al. ¹³	Malignancy probability (0–100%)	Inception-Resnet-V2	1629 images	Seoul National University Hospital, Seoul National University Bundang Hospital and SMG-SNU Boramee Medical Center	Yes (dataset from other hospitals)	No
Han et al. ¹⁴	Top 3 diagnoses, binary malignancy prediction (benign vs malignant), and treatment prediction (steroids vs antibiotics vs antivirals vs antifungals)	Model Dermatology build 2018 (SE-Net, SE-ResNet-50, VGG-19)	220,680 images	ASAN, Web, MED-NODE*, Normal, Edinburgh and SNU	Yes (datasets from other hospitals)	No
Han et al. ¹⁵	Top 5 diagnoses and malignancy score (0–100)	Model Dermatology build 2020 (SE-Net, SE-ResNeXt-101, SE-ResNeXt-50, ResNeSt-101, and ResNeSt-50)	4,204,323 images crops [unknown number of images]	Han et al. 2020 + Seven-Point Checklist Dermatology Dataset* and semi-automatically annotated images on the internet	Yes (prospective dermatology cases in Korea)	No
Jahn et al. ¹⁷	MoleAnalyzerPro: malignancy score 0–1.0 (threshold >0.5) DEXi: malignancy score 0.0–10.0 (threshold >5.0)	FotoFinder ATBM* with MoleAnalyzer Pro (Inception-v4) + 3D TBP Vectra* WB360 system with DEXi (SkinVision* was evaluated but not used for decision making)	N/A	MoleAnalyzer Pro: ISIC* + cooperating dermatologists DEXi: N/A	N/A	No
Jain et al. ¹⁸	Up to 5 of the AI's top predictions, confidence level (0–5) and similar images	Inception-v4	64,837 images	Retrospective consecutive adult cases from a teledermatology service serving 17 primary-care and specialist sites from two states in the United States.	Yes (dataset from different time period)	Yes
Kim et al. ²⁰	Top 3 diagnoses and malignancy score (0–100)	Model Dermatology build 2019 (SE-Net, SE-ResNeXt-50)	721,749 image crops [unknown number of images]	Han et al. 2020 + Seven-Point Checklist Dermatology Dataset* and semi-automatically annotated images on the internet	Yes (prospective dermatology cases in Korea)	No
Lee et al. ¹²	Nevus vs. acral MM and probability (0–100%)	ALMnet (ResNet 50)	872 images	Department of Dermatology, Severance Hospital, Seoul, Korea	No	Yes, part of the funding
Lucius et al. ¹⁶	Top diagnosis	EfficientNetB5	8313 images	HAM 10,000*	No	No
Maron et al. ²²	Nevus vs. MM and probability (0–100%)	ResNet 50	4894 images	ISIC (with a large fraction from the HAM 10,000 dataset)*	No	No
Muñoz-López et al. ¹⁸	Top 3 diagnoses	Model Dermatology build 2018 (SE-Net, SE-ResNet-50, VGG-19) (Same as Han et al. 2020)	220,680 images	ASAN, Web, MED-NODE*Normal, Edinburgh and SNU (Same as Han et al. 2020)	Yes (prospective tele-dermatology cases in Chile)	No
Tschandl et al. ¹⁰	Either multiclass probabilities, probability of malignancy or AI-based CBIR (images of similar lesions)	ResNet34	8012 images	HAM 10,000*	No	No

N/A not applicable, HAM 10,000 Human Against Machine with 10,000 training images dataset, ISIC International Skin Imaging Collaboration, ASAN Department of Dermatology at Asan Medical Center, Web images obtained from the internet, MED-NODE Department of Dermatology at the University Medical Center Groningen, and Normal: images of skin with normal or nonspecific findings, Edinburgh: Dermofit Image Library from the University of Edinburgh, SNU Seoul National University Bundang Hospital, Inje University Sanggye Paik Hospital, and Hallym University Dongtan Hospital, CBIR Content-Based Image Retrieval.

*Open-source dataset.

Table 1 | Study characteristics of the 12 included studies

Source	Target condition	Setting and design	Participants	Patients	Reference standard	Classification task	No. of cases/participant
Ba et al. ²¹	Cutaneous tumors (10 categories: BCC, SCC, MM, Bowen disease, AK, melanocytic nevus, SK, haemangioma, DF, wart)	Reader study, China	18 dermatologists from 9 different hospitals	400 randomly selected cases from the test set (40 images per category). Clinical images only. No clinical information.	Histopathology on all images	Classification of clinical images without and with AI assistance, (washout period of 2 months).	400
Cho et al. ²³	Benign (LP, melanotic macule, pyogenic granuloma, plasma cell chelitis and venous lake) vs. malignant lip disease (SCC, BCC, MM, adenocarcinoma, actinic chelitis, Bowen disease, MMIs)	Reader study, Korea	44 physicians and medical students (6 dermatologists, 12 dermatology residents, 9 non-dermatology specialists, 17 medical students)	40 randomly chosen cases (20 benign, 20 malignant). Clinical images only.	Histopathology or clinical diagnosis	Rate images as benign or malignant, first without AI assistance and then with.	40
Han et al. ^{4,14}	Malignant vs. benign skin lesion + treatment recommendation (malignant nodule, benign lesions requiring antifungals, antivirals, antibiotics, or steroid treatment, and other benign lesions)	Reader study, Korea	47 physicians (21 dermatologists, 26 dermatology residents) and 23 non-medical professionals	240 randomly selected clinical images without clinical data from the SNU dataset	Histopathology, or clinical diagnosis	Classification of clinical images as malignant or benign, with treatment suggestion. Next, AI assistance and new classification.	240
Han et al. ¹⁵	Skin lesions suspicious for skin cancer	Prospective clinical study, Korea	4 dermatology residents and 4 non-dermatology trainees. 4 dermatologists served as ground truth for un-biopsied lesions (not exposed to AI).	576 patients with suspected skin cancer (by either patient or physician) Randomization to standard clinical in-person examination without AI (n = 281) or with AI (n = 295).	Histopathology, or clinical diagnosis	If randomization to AI: patient examination, top 3 diagnoses, then AI assistance and a possibility to modify initial diagnoses. Control group: patient examination, top 3 diagnoses without AI. No dermoscopy was allowed for any study participants.	20-53/ participant
Jahn et al. ¹⁷	Nevus vs. MM	Prospective clinical study, Switzerland	7 dermatologists	114 patients (1204 lesions) with a high risk for developing a MM. In-person examination with dermoscopy.	Histopathology, or study participant in concordance with scores of the two AI tools ⁸	Assessment by dermatologist, then all melanocytic nevi ≥3 mm or any smaller suspicious lesions were assessed by the three AI tools. Dermatologist was informed of the results of the MoleAnalyzer Pro + Dexi and could modify the initial diagnosis.	N/A
Jain et al. ¹⁸	Different skin conditions, including skin cancer (120 different diagnoses)	Reader study, USA	40 medical professionals (20 primary care physicians and 20 nurse practitioners)	1048 cases from two retrospective datasets from California and Hawaii, used for validation of the algorithm. Clinical images and clinical information.	Histopathology or consensus ⁸	Provide top diagnoses. Participants were divided into two groups with the same cases but opposite assistance modalities (ie, unassisted vs. AI assisted) for each case.	1048 (half with and the rest without AI assistance)
Kim et al. ²⁰	Skin lesions suspicious for skin cancer	Prospective clinical study, Korea	11 dermatology residents, 7 interns, 10 dermatologists served as ground truth for un-biopsied lesions, (not exposed to AI).	285 patients with suspected skin cancer (by either patient or physician) were randomized to standard clinical in-person examination without AI (n = 141 patients) or with AI (n = 144 patients).	Histopathology or clinical diagnosis	If randomization to AI: patient examination, top three diagnoses. Then AI assistance and a possibility to modify initial diagnoses. Control group: patient examination, top 3 diagnoses without AI.	N/A
Lee et al. ¹²	Nevus vs. acral MM	Reader study, Korea	60 physicians (20 dermatologists, 20 dermatology residents, 20 primary care physicians)	100 cases from the test-set. Dermoscopic images and clinical information.	Histopathology or consensus (3 dermatologists and follow-up)	Classification of 100 dermoscopic images. After two weeks same images + clinical info. After another two weeks same images + clinical info + AI assistance. Rate diagnosis + management.	100




Fig. 2 | SROC Curves. SE sensitivity, SP specificity. Performance of clinicians with no AI assistance (a) compared to AI-assisted clinicians (b) in the included studies.

نتایج متاآنالیزها

برآورد خلاصه حساسیت برای متخصصان بالینی به طور کلی 74.8٪ (95٪ فاصله اطمینان 68.6–80.1) و ویژگی 81.5٪ (87.3–73.9) بود. دقت تشخیصی کلی با کمک هوش مصنوعی به حساسیت تجمیع شده 81.1٪ (86.5–74.4) و ویژگی 86.1٪ (79.2–90.9) افزایش یافت. منحنی‌های SROC و نمودارهای جنگلی ده مطالعه برای متخصصان بالینی بدون در مقابل با کمک هوش مصنوعی به ترتیب در شکل‌های 2 و 3 نشان داده شده‌اند، که در آن ناهمگونی کمتری در حساسیت متخصصان بالینی به طور کلی در مقایسه با متخصصان بالینی با کمک هوش مصنوعی مشاهده می‌شود.

برای بررسی اثر کمک هوش مصنوعی با جزئیات بیشتر، تحلیل‌های زیرگروهی را بر اساس سطح تجربه بالینی، وظیفه آزمون و نوع تصویر انجام دادیم (جدول 3). مشاهده کردیم که متخصصان پوست بالاترین دقت تشخیصی را از نظر حساسیت و ویژگی داشتند. دستیاران (شامل دستیاران پوست و انترن‌ها) دومین گروه دقیق بودند، به دنبال آن غیرمتخصصان پوست (شامل ارائه‌دهندگان مراقبت اولیه، پرستاران حرفه‌ای و دانشجویان پزشکی). قابل توجه است که کمک هوش مصنوعی حساسیت و ویژگی تمام گروه‌های متخصصان بالینی را به طور قابل توجهی بهبود بخشید. گروه غیرمتخصصان پوست به نظر می‌رسد بیشترین سود را از کمک هوش مصنوعی از نظر بهبود حساسیت تجمیع شده (13+ امتیاز) و ویژگی (11+ امتیاز) برده باشند. برای وظیفه طبقه‌بندی، حساسیت هر دو طبقه‌بندی دودویی (بدخیم در مقابل خوش‌خیم) و تشخیص برتر با کمک هوش مصنوعی بهبود یافت. در همین حال، کمک هوش مصنوعی تنها برای طبقه‌بندی برتر ویژگی تجمیع شده را به طور قابل توجهی بهبود بخشید و به ویژگی 88.8٪ (90.8–86.5) رسید. برای نوع تصویر تفاوت معنی‌داری مشاهده نشد.

هیچ شواهدی از اثر مطالعه کوچک در آزمون عدم تقارن رگرسیون برای انسان‌ها بدون ($p = 0.33$) و با کمک هوش مصنوعی ($p = 0.23$) وجود نداشت. برای نمودارهای قیفی به شکل تکمیلی 1 مراجعه کنید. آزمون همبستگی اسپیرمن نشان داد که احتمال وجود اثر آستانه مثبت برای هر دو گروه کم است. تحلیل‌های حساسیت نشان داد که حذف داده‌های پرت کمی حساسیت و ویژگی تجمیع شده را در هر دو گروه افزایش می‌دهد در حالی که حساسیت و ویژگی تجمیع شده عمدتاً زمانی که مطالعه با کیفیت پایین حذف شد، بدون تغییر باقی ماند (جدول تکمیلی 2).

بحث

این مرور نظام‌مند و متاآنالیز شامل 12 مطالعه و 67,700 ارزیابی تشخیصی بالقوه سرطان پوست توسط متخصصان بالینی با و بدون کمک هوش مصنوعی بود. یافته‌های ما پتانسیل تصمیم‌گیری کمک‌شده با هوش مصنوعی را در تشخیص سرطان

پوست برجسته می‌کند. تمام متخصصان بالینی، صرف نظر از سطح آموزش آن‌ها، هنگامی که توسط الگوریتم‌های هوش مصنوعی کمک می‌شدند، عملکرد تشخیصی بهبود یافته‌ای نشان دادند. با این حال، درجه بهبود در تخصص‌ها متفاوت بود، با این که متخصصان پوست کمترین افزایش را در دقت تشخیصی نشان دادند و غیرمتخصصان پوست، از جمله ارائه‌دهندگان مراقبت اولیه، بیشترین بهبود را نشان دادند. این نتایج نشان می‌دهد که کمک هوش مصنوعی ممکن است به ویژه برای متخصصان بالینی بدون آموزش گسترده در پوست‌شناسی مفید باشد. با توجه به این که بسیاری از دستگاه‌های هوش مصنوعی پوست‌شناسی اخیراً تأیید نظارتی در اروپا را کسب کرده‌اند، از جمله برخی الگوریتم‌های دارای علامت CE که در مطالعات تحلیل شده استفاده شده‌اند^{24,25}، کمک هوش مصنوعی ممکن است به زودی بخش استاندارد از جعبه ابزار متخصص پوست شود. بنابراین درک بهتر تعامل بین انسان و هوش مصنوعی در تصمیم‌گیری بالینی مهم است.

در حالی که چندین مطالعه برای ارزیابی استفاده پوست‌شناسی از ابزارهای جدید هوش مصنوعی انجام شده است، مرور ما از مطالعات منتشر شده نشان داد که اکثر آن‌ها تنها عملکرد متخصص بالینی انسان را با ابزارهای هوش مصنوعی مقایسه کرده‌اند، بدون در نظر گرفتن این که متخصصان بالینی چگونه با این ابزارها تعامل می‌کنند. دو مطالعه در این مرور نظام‌مند و متاآنالیز گزارش دادند که متخصصان بالینی هنگامی که ابزار هوش مصنوعی توصیه‌های نادرست ارائه می‌دهد، عملکرد بدتری دارند^{10,19}. این یافته بر اهمیت الگوریتم‌های دقیق و قابل اعتماد در اطمینان از این که پیاده‌سازی هوش مصنوعی نتایج بالینی را بهبود می‌بخشد، تأکید می‌کند و نیاز به تحقیقات بیشتر برای اعتبارسنجی تصمیم‌گیری کمک‌شده با هوش مصنوعی در عمل پزشکی را برجسته می‌کند. قابل توجه است که در یک مطالعه اخیر توسط باراتا و همکاران²⁶، نویسندگان نشان دادند که یک مدل یادگیری تقویتی که ترجیحات انسان را در بر می‌گرفت، از یک مدل یادگیری نظارت‌شده بهتر عمل کرد. علاوه بر این، عملکرد متخصصان پوست شرکت‌کننده را از نظر دقت تشخیصی و تصمیمات مدیریت بهینه بالقوه سرطان پوست در مقایسه با یک مدل یادگیری نظارت‌شده یا بدون کمک هوش مصنوعی بهبود بخشید. از این رو، توسعه الگوریتم‌ها در همکاری با متخصصان بالینی به نظر می‌رسد برای بهینه‌سازی نتایج بالینی مهم باشد.




Fig. 3 | Flow diagram of the study selection process. Forest plots. Meta-analysis results of the diagnostic performance of clinicians without (a) or with (b) AI assistance.

Table 3 | Subgroup analysis by clinician's experience level, image type and classification task

Subgroups (N)	Clinicians (95% CI)	AI-assisted clinicians (95% CI)	p-value ^a
Dermatologists	SE 81.8% (76.1-86.4)	SE 86.5% (81.9-90.0)	0.007
(N=7)	SP 79.2% (70.6-85.7)	SP 87.2% (81.1-91.5)	<0.001
Residents ^b	SE 77.8% (71.7-83.0)	SE 85.4% (80.7-89.1)	0.003
(N=6)	SP 80.1% (70.2-87.3)	SP 87.6% (80.4-92.4)	0.007
Other medical professionals ^b	SE 66.3% (55.8-75.3)	SE 79.3% (71.0-85.7)	0.003
(N=4)	SP 70.1% (55.9-81.3)	SP 80.9% (69.4-88.7)	0.011
Binary malignancy prediction	SE 73.0% (63.8-80.6)	SE 84.2% (77.6-89.1)	0.027
(N=5)	SP 78.4% (63.8-88.2)	SP 79.6% (65.5-88.9)	0.892
Top diagnosis	SE 73.3% (63.0-81.6)	SE 81.2% (72.8-87.5)	<0.001
(N=5)	SP 81.4% (78.1-84.3)	SP 88.8% (86.5-90.8)	<0.001
Clinical images	SE 72.7% (61.7-81.6)	SE 79.6% (70.1-86.6)	0.300
(N=5)	SP 80.4% (65.8-89.8)	SP 85.3% (73.1-92.6)	0.528
Dermoscopic images	SE 78.2% (67.6-86.1)	SE 84.8% (76.6-90.4)	0.258
(N=4)	SP 79.8% (71.4-86.2)	SP 84.0% (77.0-89.2)	0.380

N: number of studies, SE: sensitivity, SP: specificity, CI: confidence interval.

^aResidents including dermatology residents and interns.

^bOther medical professionals including general practitioners, other medical specialists, nurse practitioners and medical students.

^cBased on two-sided z-test.

تنها دو مطالعه تأثیر یک تکنیک قابل توضیح (CBIR) را بر دقت تشخیصی یا مفید بودن درک شده پزشک بررسی کردند. کاربرد بالینی واقعی روش‌های قابل توضیح نیاز به بررسی بیشتر دارد، و روش‌های فعلی باید به عنوان ابزاری برای پرسوجو و عیب‌یابی مدل‌های هوش مصنوعی دیده شوند²⁷. علاوه بر این، تحقیقات قبلی نشان داده‌اند که ویژگی‌های رفتاری انسان می‌تواند بر اعتماد و اتکا به کمک هوش مصنوعی به طور کلی تأثیر بگذارد^{28,29}. به عنوان مثال، درک و اعتماد به نفس یک متخصص بالینی نسبت به عملکرد هوش مصنوعی در یک وظیفه خاص ممکن است بر تصمیم آن‌ها برای گنجاندن توصیه هوش مصنوعی در تصمیم‌گیری‌شان تأثیر بگذارد³⁰. علاوه بر این، تحقیقات همچنین نشان داده است که اعتماد به نفس انسان در تصمیم خود، سطح اطمینان هوش مصنوعی، و این که آیا انسان و هوش مصنوعی موافق هستند، همه بر این که آیا انسان توصیه هوش مصنوعی را در بر می‌گیرد، تأثیر می‌گذارند³⁰. برای اطمینان از این که کمک هوش مصنوعی دقت تشخیصی را پشتیبانی و بهبود می‌بخشد، تحقیقات آینده باید بررسی کنند که چگونه عواملی مانند ویژگی‌های شخصیتی²⁹، سبک شناختی²⁸ و سوگیری‌های شناختی³¹ بر عملکرد تشخیصی در موقعیت‌های بالینی واقعی تأثیر می‌گذارند. چنین تحقیقاتی به اطلاع‌رسانی ادغام هوش مصنوعی در عمل بالینی کمک خواهد کرد.

یافته‌های ما نشان می‌دهد که کمک هوش مصنوعی ممکن است به ویژه برای متخصصان بالینی با تجربه کمتر مفید باشد، که با مطالعات قبلی تعامل انسان و هوش مصنوعی در رادیولوژی سازگار است³². این پتانسیل کمک هوش مصنوعی را به عنوان یک ابزار آموزشی برای غیرمتخصصان پوست و برای بهبود عملکرد تشخیصی در محیط‌هایی مانند مراقبت اولیه یا برای متخصصان پوست در حال آموزش برجسته می‌کند. در یک تحلیل زیرگروهی، تفاوت معنی‌داری بین متخصصان پزشکی دیگر کمک‌شده با هوش مصنوعی در مقابل متخصصان پوست غیرکمک‌شده مشاهده نکردیم (داده نشان داده نشده). با این حال، این زمینه مستلزم تحقیقات بیشتر است.

برخی محدودیت‌ها باید هنگام تفسیر یافته‌ها در نظر گرفته شوند. اول، در میان ده مطالعه‌ای که داده کافی برای انجام متاآنالیز ارائه دادند، تفاوت‌هایی در طرح، تعداد و سطح تجربه شرکت‌کنندگان، تعریف وضعیت هدف، وظیفه طبقه‌بندی، و خروجی و آموزش الگوریتم وجود داشت. در مجموع، این ناهمگونی به این معنی است که مقایسه‌های مستقیم باید با دقت تفسیر شوند. علاوه بر این، احتیاط برای تفسیر تحلیل‌های زیرگروهی به دلیل حجم نمونه کوچک زیرگروه‌ها (تا هفت) و ساختار داده (یعنی اندازه‌گیری‌های تکراری) لازم است زیرا همان شرکت‌کنندگان تصاویر بالینی را هم بدون و هم با کمک هوش مصنوعی در اکثر مطالعات بررسی کردند. با توجه به تعداد کم مطالعات، از انجام تحلیل‌های زیرگروهی بیشتر، مانند مقایسه تشخیص‌های خاص سرطان در زیرمجموعه مقالاتی که این‌ها در دسترس هستند، خودداری کردیم. با وجود این محدودیت‌ها، نتایج ما از این متاآنالیز از این مفهوم حمایت می‌کند که کمک هوش مصنوعی می‌تواند اثر مثبتی بر عملکرد تشخیصی متخصص بالینی داشته باشد. ما قادر بودیم برای منابع بالقوه ناهمگونی، از جمله وظیفه تشخیصی و سطح تجربه متخصص بالینی هنگام مقایسه دقت تشخیصی متخصصان بالینی با در مقابل بدون کمک هوش مصنوعی، تنظیم کنیم. علاوه بر این، هیچ نشانه‌ای از سوگیری انتشار و احتمال کم اثرات آستانه مشاهده نشد. در نهایت، یافته‌ها قوی بودند به طوری که حساسیت و ویژگی تجمیع‌شده پس از حذف داده‌های پرت یا مطالعات با کیفیت پایین تقریباً ثابت ماند.

شایان ذکر است که تعداد کمی از مطالعات هم داده‌های بالینی و هم تصاویر درماتوسکوپی را در اختیار متخصصان بالینی شرکت‌کننده قرار دادند، که در یک موقعیت بالینی واقعی در دسترس خواهد بود. تحقیقات قبلی نشان داده است که استفاده از درماتوسکوپی امکان بهبود نسبی دقت تشخیص ملانوما را تقریباً 50٪ در مقایسه با چشم غیرمسلح فراهم می‌کند⁵. در یکی از این مطالعات، شرکت‌کنندگان صراحتاً مجاز به استفاده از درماتوسکوپی در طول معاینه بیمار نبودند¹⁹. به طور کلی، تنها چهار مطالعه در یک محیط بالینی آینده‌نگر انجام شدند، و سه مورد از این‌ها می‌توانست برای متاآنالیز گنجانده شود. بنابراین، اکثر رتبه‌بندی‌های تشخیصی در این متاآنالیز در محیط‌های آزمایشی انجام شد و لزوماً تصمیمات گرفته شده در یک موقعیت واقعی بالینی را منعکس نمی‌کند.

یکی از نگرانی‌های اصلی در مورد دقت ابزارهای هوش مصنوعی به کیفیت داده‌هایی که روی آن آموزش دیده‌اند متکی است³³. از آنجا که تنها سه مطالعه از مجموعه داده‌های در دسترس عموم استفاده کردند، ارزیابی کیفیت داده دشوار است. علاوه بر این، رنگ‌های پوست تیره‌تر در مجموعه داده‌های مطالعات وارد شده کمتر ارائه شده بودند، که یک مشکل شناخته شده در این زمینه است، زیرا اکثر مقالات خروجی‌های رنگ پوست را گزارش نمی‌دهند³⁴. با این حال، مجموعه داده‌هایی با رنگ‌های پوست متنوع توسعه یافته و به صورت عمومی در دسترس قرار گرفته‌اند تا تلاشی برای کاهش نابرابری در عملکرد هوش مصنوعی در پوست‌شناسی باشد^{35,36}. علاوه بر این، تعداد کمی از مطالعات اطلاعات

مفصلی درباره منشأ و تعداد تصاویری که برای آموزش، اعتبارسنجی و آزمایش ابزار هوش مصنوعی استفاده شده بود ارائه دادند و تعاریف مختلفی از این اصطلاحات در مطالعات مختلف استفاده شد. نیاز به دستورالعمل‌های شفافیت بهتر برای گزارش ابزار هوش مصنوعی وجود دارد تا کاربران و خوانندگان بتوانند محدودیت‌ها و قابلیت‌های این ابزارهای تشخیصی را درک کنند. تلاش‌هایی برای توسعه دستورالعمل‌هایی که برای این منظور سازگار شده‌اند، از جمله دستورالعمل‌های ³⁷ STARD-AI، TRIPOD-AI و ³⁸ PROBAST-AI، و همچنین دستورالعمل‌های مختص پوست‌شناسی ³⁹ CLEAR Derm در حال انجام است. علاوه بر این، دستورالعمل‌های ⁴⁰ PRISMA-AI برای مرورهای نظام‌مند و متاآنالیز در حال توسعه هستند. اینها ابتکارات امیدوارکننده‌ای هستند که امیدواریم گزارش و ارزیابی تحقیقات ابزار تشخیصی هوش مصنوعی را شفاف‌تر کنند.

نتیجه‌گیری

نتایج این مرور نظام‌مند و متاآنالیز نشان می‌دهد که متخصصان بالینی بدون توجه به سطح تجربه آن‌ها از کمک هوش مصنوعی در تشخیص سرطان پوست سود می‌برند. متخصصان بالینی با کمترین تجربه در پوست‌شناسی ممکن است بیشترین سود را از کمک هوش مصنوعی ببرند. یافته‌های ما به موقع است زیرا انتظار می‌رود هوش مصنوعی در آینده نزدیک به طور گسترده در کار بالینی در سراسر جهان پیاده‌سازی شود. قابل توجه است که تنها چهار مطالعه شناسایی شده در محیط‌های بالینی انجام شدند، که سه مورد از آن‌ها می‌توانست در متاآنالیز گنجانده شود. بنابراین، نیاز فوری برای مطالعات بالینی آینده‌نگر بیشتر در محیط‌های واقعی که قرار است هوش مصنوعی در آن‌ها استفاده شود وجود دارد تا اثر هوش مصنوعی بر تصمیم‌گیری بالینی بهتر درک و پیش‌بینی شود.

روش‌ها

استراتژی جستجو و معیارهای انتخاب

چهار پایگاه داده الکترونیکی شامل PubMed، Embase، Institute of Electrical and Electronics Engineers (Xplore) و Scopus را برای مقالات دارای داور همتا در مورد تشخیص سرطان پوست با کمک هوش مصنوعی، بدون محدودیت زبانی از 1 ژانویه 2017 تا 8 نوامبر 2022 جستجو کردیم. اصطلاحات جستجو برای چهار مفهوم کلیدی ترکیب شدند: (1) هوش مصنوعی، (2) سرطان پوست، (3) تشخیص، (4) پزشکان. استراتژی کامل جستجو در مطالب تکمیلی (Supplementary Table 3) موجود است. سال 2017 را به عنوان نقطه قطع برای این مرور انتخاب کردیم، زیرا این سالی بود که برای اولین بار گزارش شد یادگیری عمیق در سطحی قابل مقایسه با متخصصان پوست عمل می‌کند، به ویژه در مطالعه برجسته Esteva و همکاران، که نشان داد فناوری هوش مصنوعی به سطحی مفید از نظر بالینی در کمک به تشخیص سرطان پوست رسیده است.

برای غربالگری چکیده مقالات غیرانگلیسی از نرم‌افزار Google Translate استفاده کردیم. جستجوهای دستی برای مقالات کنفرانس‌ها، شامل NeurIPS، HICSS، ICML، ICLR، AAAI، CVPR، CHIL و ML4Health، و برای شناسایی مقالات مرتبط بیشتر با مرور کتاب‌شناسی و استنادهای مقالات غربال شده و جستجوی Google Scholar انجام شد.

مطالعاتی را که دقت تشخیصی متخصصان بالینی در تشخیص سرطان پوست را با و بدون کمک هوش مصنوعی مقایسه می‌کردند، وارد کردیم. اگر مطالعات داده‌های تشخیصی از متخصصان پزشکی غیر از پزشکان ارائه می‌دادند، این داده‌ها نیز تا زمانی که مطالعه شامل پزشکان نیز می‌شد، برای تحلیل گنجانده می‌شد. با این حال، مطالعات را حذف کردیم اگر: (1) تشخیص از تصاویر ضایعات پوستی یا ویژگی حضور یا عدم حضور (مانند لام‌های پاتولوژی)، (2) دقت تشخیصی تنها بین متخصصان بالینی و یک الگوریتم هوش مصنوعی مقایسه شده بود، (3) از تکنیک‌های غیر یادگیری عمیق استفاده شده بود، یا (4) مقالات، سرمقاله‌ها، مرورها و گزارش‌های موردی بودند. ما تخصص شرکت‌کنندگان، طرح مطالعه یا حجم نمونه، استاندارد مرجع، یا تشخیص پوستی را در صورتی که حداقل یک بدخیمی پوستی در مطالعه گنجانده شده بود، محدود نکردیم. با نه نویسنده برای درخواست داده‌های اضافی و توضیحات لازم برای متاآنالیز تماس گرفتیم و داده‌ها را از پنج نفر و توضیحات را از دو نفر دریافت کردیم. در چهار مطالعه، داده‌های خام برای همه آزمایش‌ها یا ضایعات در دسترس نبود، و متاآنالیز ما داده‌های موجود را شامل شد. مطالعات با داده‌های ناکافی برای ساخت جداول احتمالی در مرور نظام‌مند گنجانده شدند اما در متاآنالیز نه.

سه مرورگر ارزیابی واجد شرایط بودن، استخراج داده و ارزیابی کیفیت مطالعه را انجام دادند. (IK, JK, ZRC) برنامه‌های استاندارد پرکاربرد برای حذف تکراری‌ها، غربالگری عنوان و چکیده، و مرور متن کامل (Covidence) و استخراج داده (Microsoft Excel) استفاده شد. مرورگران جفتی به طور مستقل عناوین و چکیده‌ها را با استفاده از معیارهای از پیش تعریف شده غربال کردند و داده‌ها را استخراج کردند. اختلاف نظر از طریق بحث با مرورگر سوم حل شد. IK داده‌های استخراج شده را وارد جدول خلاصه برای مرور نظام‌مند کرد و دو مرورگر (IK) و (ZRC) آن را تأیید کردند. JK داده‌های استخراج شده را وارد و برای متاآنالیز آماده کرد و دو مرورگر (ZRC) و (IK) آن را تأیید کردند. آمارشناس زیستی (AL) داده‌های نهایی برای متاآنالیز را مرور و تأیید کرد. همه نویسندگان همکار جداول و شکل‌های نهایی را مرور کردند. این مرور نظام‌مند و متاآنالیز از دستورالعمل‌های PRISMA DTA پیروی کرد و پروتکل مطالعه در PROSPERO ثبت شد. (CRD42023391560)

تحلیل داده

اطلاعات کلیدی، شامل موارد مثبت واقعی، مثبت کاذب، منفی کاذب و منفی واقعی در میان متخصصان بالینی با و بدون کمک هوش مصنوعی را استخراج کردیم. در صورت امکان، جداول احتمالی ایجاد کردیم تا دقت آزمون تشخیصی را از نظر حساسیت و ویژگی جمع‌شده تخمین بزنیم. اطلاعات اضافی درباره الگوریتم هوش مصنوعی (مانند معماری، منابع تصویر، اعتبارسنجی و روش کمک هوش مصنوعی)، شرکت‌کنندگان، بیماران، وضعیت هدف، استاندارد مرجع، محیط و طرح مطالعه، و تأمین مالی استخراج شد.

یک ابزار تجدید نظر شده برای ارزیابی کیفیت روش‌شناختی مطالعات دقت تشخیصی (QUADAS-2) برای ارزیابی خطر سوگیری و نگرانی‌های قابلیت کاربرد هر مطالعه در چهار حوزه: انتخاب بیمار، آزمون شاخص، استاندارد مرجع، و جریان و زمان‌بندی استفاده شد. (Supplementary Table 1) یک جفت مرورگر به طور مستقل حوزه‌ها را ارزیابی کردند، رتبه‌بندی‌ها را مقایسه کردند و در صورت تعارض، اختلافات را از طریق بحث‌هایی که توسط مرورگر سوم هدایت می‌شد (IK, JK, ZRC) حل کردند.

از بسته Metandi برای Stata 17 (College Station, TX) برای محاسبه برآوردهای خلاصه حساسیت و ویژگی با فواصل اطمینان 95% (95% CI) با کمک هوش مصنوعی در مقایسه با انسان‌ها بدون کمک هوش مصنوعی با استفاده از یک مدل دو متغیره استفاده کردیم. منحنی‌های خلاصه مشخصه عملکرد گیرنده (SROC) برای نمایش بصری برآوردهای خلاصه حساسیت و ویژگی با منطقه اطمینان 95% و منطقه پیش‌بینی 95% ترسیم شدند، که به مناطق اطمینانی اشاره دارد که حساسیت و ویژگی مطالعات آینده احتمالاً در آن قرار می‌گیرند. مدل‌های دو متغیره به طور جداگانه برای متخصصان بالینی با و بدون کمک هوش مصنوعی انجام شدند، زیرا بسته Metandi نمی‌توانست طرح جفتی داده‌ها را مدیریت کند. یک مدل اثرات تصادفی برای در نظر گرفتن ناهمگونی پیش‌بینی‌شده بین مطالعات اعمال کردیم، که به طور بالقوه به دلیل واریانس داده‌ها، از جمله استفاده از الگوریتم‌های هوش مصنوعی مختلف، متخصصان پزشکی و محیط‌های مطالعه بود. ناهمگونی با بازرسی بصری گرافیک‌ها، از جمله منحنی SROC و نمودارهای جنگلی ارزیابی شد. علاوه بر این، یک تحلیل متارگرسیون دو متغیره با استفاده از بسته Megriogit (Stata 17, College Station, TX) بر اساس حضور یا عدم حضور کمک هوش مصنوعی، برای هر سطح تجربه در پوست‌شناسی (متخصصان پوست، دستیاران، متخصصان پزشکی غیرپوست)، نوع وظیفه تشخیصی (طبقه‌بندی دودویی یا تشخیص برتر) و نوع تصویر (بالینی یا درماتوسکوپی) به طور جداگانه انجام دادیم، تا دقت تشخیصی بر اساس کمک هوش مصنوعی مقایسه و برای ناهمگونی بالقوه ناشی از این عوامل تنظیم شود. برای بررسی وجود اثر آستانه مثبت، ضریب همبستگی اسپیرمن بین حساسیت و ویژگی محاسبه شد. تحلیل‌های حساسیت از پیش برنامه‌ریزی شده با حذف داده‌های پرت بالقوه، مطالعات با روش‌شناسی ضعیف (جایی که حداقل سه حوزه به عنوان سوگیری نامشخص یا بالا رتبه‌بندی شده بودند) و مطالعات با استانداردهای مرجع غیر از فقط هیستوپاتولوژی انجام شد. سوگیری انتشار را با استفاده از آزمون عدم تقارن نمودار قیفی Deeks بررسی کردیم، که یک رگرسیون روی نمودارهای قیفی اندازه نمونه مؤثر در مقابل نسبت شانس تشخیصی اجرا می‌کند. آماره کاپا را برای ارزیابی توافق بین ارزیاب‌های QUADAS-2 محاسبه کردیم. تمام معنی‌داری آماری در سطح $p < 0.05$ تعیین شد.

دسترسی به داده

E.L. به تمام داده‌های مطالعه دسترسی کامل دارد و مسئولیت یکپارچگی داده‌ها و دقت تحلیل داده را بر عهده دارد. تمام مواد مطالعه در صورت درخواست منطقی از نویسنده مسئول در دسترس هستند.

دسترسی به کد

کدهای استفاده شده در تحلیل این مطالعه در صورت درخواست منطقی از نویسنده مسئول در دسترس قرار خواهند گرفت.

تاریخ‌ها

دریافت: 22 سپتامبر 2023؛ پذیرش: 5 فوریه 2024؛
انتشار آنلاین: 09 آوریل 2024

References

1. Brynjolfsson, E. & Mitchell, T. What can machine learning do? Workforce implications. *Science* 358, 1530–1534 (2017).
2. Wu, E. et al. How medical AI devices are evaluated: limitations and recommendations from an analysis of FDA approvals. *Nat. Med.* 27, 582–584 (2021).
3. Yu, K.-H., Beam, A. L. & Kohane, I. S. Artificial intelligence in healthcare. *Nat. Biomed. Eng.* 2, 719–731 (2018).
4. Topol, E. J. High-performance medicine: the convergence of human and artificial intelligence. *Nat. Med.* 25, 44–56 (2019).
5. Kittler, H., Penamberger, H., Wolff, K. & Binder, M. Diagnostic accuracy of dermoscopy. *Lancet Oncol.* 3, 159–165 (2002).
6. Marghoob, A. A. & Scope, A. The complexity of diagnosing melanoma. *J. Investig. Dermatol.* 129, 11–13 (2009).
7. Tschandl, P. et al. Comparison of the accuracy of human readers versus machine-learning algorithms for pigmented skin lesion classification: an open, web-based, international, diagnostic study. *Lancet Oncol.* 20, 938–947 (2019).
8. Haenssle, H. A. et al. Man against machine reloaded: performance of a market-approved convolutional neural network in classifying a broad spectrum of skin lesions in comparison with 96 dermatologists working under less artificial conditions. *Ann. Oncol.* 31, 137–143 (2020).
9. Esteva, A. et al. Dermatologist-level classification of skin cancer with deep neural networks. *Nature* 542, 115–118 (2017).
10. Tschandl, P. et al. Human–computer collaboration for skin cancer recognition. *Nat. Med.* 26, 1229–1234 (2020).
11. Ngiam, K. Y. & Khor, I. W. Big data and machine learning algorithms for health-care delivery. *Lancet Oncol.* 20, e262–e273 (2019).
12. Lee, S. et al. Augmented decision-making for acral lentiginous melanoma detection using deep convolutional neural networks. *J. Eur. Acad. Dermatol. Venereol.* 34, 1842–1850 (2020).
13. Cho, S. I. et al. Dermatologist-level classification of malignant lip diseases using a deep convolutional neural network. *Br. J. Dermatol.* 182, 1388–1394 (2020).

Han, S. S. et al. Augmented intelligence dermatology: deep neural networks empower .14
 medical professionals in diagnosing skin cancer and predicting treatment options for 134
 skin disorders. *J. Investig. Dermatol.* 140, 1753–1761 (2020).

Jain, A. et al. Development and assessment of an artificial intelligence-based tool for skin .15
 condition diagnosis by primary care physicians and nurse practitioners in teledermatology
 practices. *JAMA Netw. Open* 4, e217249–e217249 (2021).

Muñoz-López, C. et al. Performance of a deep neural network in teledermatology: a .16
 single-centre prospective diagnostic study. *J. Eur. Acad. Dermatol. Venereol.* 35, 546–
 553 (2021).

Jahn, A. S. et al. Over-detection of melanoma-suspect lesions by a CE-certified .17
 smartphone app: performance in comparison to dermatologists, 2D and 3D convolutional
 neural networks in a prospective data set of 1204 pigmented skin lesions involving
 patients' perception. *Cancers* 14, 3829 (2022).

Lucius, M. et al. Deep neural frameworks improve the accuracy of general practitioners .18
 in the classification of pigmented skin lesions. *Diagnostics* 10, 969 (2020).

Han, S. S. et al. Evaluation of artificial intelligence-assisted diagnosis of skin neoplasms: .19
 a single-center, paralleled, unmasked Randomized Controlled Trial. *J. Investig.*
Dermatol. 142, 2353–2362.e2352 (2022).

Kim, Y. J. et al. Augmenting the accuracy of trainee doctors in diagnosing skin lesions .20
 suspected of skin neoplasms in a real-world setting: a prospective controlled before-and-
 after study. *PLoS One* 17, e0260895 (2022).

Ba, W. et al. Convolutional neural network assistance significantly improves .21
 dermatologists' diagnosis of cutaneous tumours using clinical images. *Eur. J. Cancer* 169,
 156–165 (2022).

Maron, R. C. et al. Artificial intelligence and its effect on dermatologists' accuracy in .22
 dermoscopic melanoma image classification: web-based survey study. *J. Med. Internet*
Res. 22, e18091 (2020).

Bowker, A. H. A test for symmetry in contingency tables. *J. Am. Stat. Assoc.* 43, 572– .23
 574 (1948).

Beltrami, E. J. et al. Artificial intelligence in the detection of skin cancer. *J. Am. Acad.* .24
Dermatol. 87, 1336–1342 (2022).

Young, A. T., Xiong, M., Pfau, J., Kaiser, M. J. & Wei, M. L. Artificial intelligence in .25
 dermatology: a primer. *J. Investig. Dermatol.* 140, 1504–1512 (2020).

Barata, C. et al. A reinforcement learning model for AI-based decision support in skin .26
 cancer. *Nat. Med.* 29, 1941–1946 (2023).

Ghassemi, M., Oakden-Rayner, L. & Beam, A. L. The false hope of current approaches .27
 to explainable artificial intelligence in health care. *Lancet Digital Health* 3, e745–e750
 (2021).

Krakowski, S. M., Haftor, D., Luger, J., Pashkevich, N. & Raisch, S. Humans and .28
 algorithms in organizational decision making: evidence from a field experiment. *Acad.*
Manag. Proc. 2019, 16633 (2019).

Park, J. & Woo, S. E. Who likes artificial intelligence? personality predictors of attitudes .29
 toward artificial intelligence. *J. Psychol.* 156, 68–94 (2022).

Vodrahalli, K., Daneshjou, R., Gerstenberg, T. & Zou, J. Do humans trust advice more if .30
 it comes from AI? An analysis of human-ai interactions. In *Proc. 2022 AAAI/ACM*

- Conference on AI, Ethics, and Society 763–777 (Association for Computing Machinery, Oxford, United Kingdom, 2022).
- Ludolph, R. & Schulz, P. J. Debiasing health-related judgments and decision making: a systematic review. *Med. Decis. Mak.* 38, 3–13 (2018).
- Gaube, S. et al. Non-task expert physicians benefit from correct explainable AI advice when reviewing X-rays. *Sci. Rep.* 13, 1383 (2023).
- Breck, E., Polyzotis, N., Roy, S., Whang, S. & Zinkevich, M. Data validation for machine learning. In *Proceedings of the Conference on Systems and Machine Learning*, (2019).
- Daneshjou, R., Smith, M. P., Sun, M. D., Rotemberg, V. & Zou, J. Lack of transparency and potential bias in artificial intelligence data sets and algorithms: a scoping review. *JAMA Dermatol.* 157, 1362–1369 (2021).
- Daneshjou, R. et al. Disparities in dermatology AI performance on a diverse, curated clinical image set. *Sci. Adv.* 8, eabq6147 (2022).
- Groh, M. et al. Evaluating Deep Neural Networks Trained on Clinical Images in Dermatology with the Fitzpatrick 17K Dataset. 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 1820–1828 (2021).
- Sounderajah, V. et al. Developing a reporting guideline for artificial intelligence-centred diagnostic test accuracy studies: the STARD-AI protocol. *BMJ Open* 11, e047709 (2021).
- Collins, G. S. et al. Protocol for development of a reporting guideline (TRIPOD-AI) and risk of bias tool (PROBAST-AI) for diagnostic and prognostic prediction model studies based on artificial intelligence. *BMJ Open* 11, e048008 (2021).
- Daneshjou, R. et al. Checklist for evaluation of image-based artificial intelligence reports in dermatology: CLEAR Derm consensus guidelines from the international skin imaging collaboration artificial intelligence working group. *JAMA Dermatol.* 158, 90–96 (2022).
- Cacciamani, G. E. et al. PRISMA AI reporting guidelines for systematic reviews and meta-analyses on AI in healthcare. *Nat. Med.* 29, 14–15 (2023).
- McInnes, M. D. F. et al. Preferred reporting items for a systematic review and meta-analysis of diagnostic test accuracy studies: the PRISMA-DTA statement. *JAMA* 319, 388–396 (2018).
- Whiting, P. F. et al. QUADAS-2: a revised tool for the quality assessment of diagnostic accuracy studies. *Ann. Intern. Med.* 155, 529–536 (2011).
- Harbord, R. M. & Whiting, P. metandi: meta-analysis of diagnostic accuracy using hierarchical logistic regression. *Stata J.* 9, 211–229 (2009).
- Reitsma, J. B. et al. Bivariate analysis of sensitivity and specificity produces informative summary measures in diagnostic reviews. *J. Clin. Epidemiol.* 58, 982–990 (2005).
- Macaskill P, T. Y., et al. editor(s). In *Cochrane Handbook for Systematic Reviews of Diagnostic Test Accuracy* 1–46 (Cochrane, London, 2022).
- Kim, K. W., Lee, J., Choi, S. H., Huh, J. & Park, S. H. Systematic review and meta-analysis of studies evaluating diagnostic test accuracy: a practical review for clinical researchers-Part I. General Guidance and Tips. *Korean J. Radio.* 16, 1175–1187 (2015).
- Takwoingi, Y. et al. Chapter 10: Undertaking meta-analysis. Draft version (4 October 2022) for inclusion in: Deeks, J. J., Bossuyt, P. M., Leeftang, M. M., Takwoingi, Y. In *Cochrane Handbook for Systematic Reviews of Diagnostic Test Accuracy* 1–77 (Cochrane, London, 2022).

Zamora, J., Abaira, V., Muriel, A., Khan, K. & Coomarasamy, A. Meta-DISC: a software for meta-analysis of test accuracy data. BMC Med. Res. Methodol. 6, 31–31 (2006).

Harrer, M., Cuijpers, P., Furukawa, T. A. & Ebert, D. D. Doing Meta-Analysis With R: A Hands-On Guide, (Chapman & Hall/CRC Press, Boca Raton, FL and London, 2021).

Deeks, J. J., Macaskill, P. & Irwig, L. The performance of tests of publication bias and other sample size effects in systematic reviews of diagnostic test accuracy was assessed. J. Clin. Epidemiol. 58, 882–893 (2005).

تشکر و قدردانی

این پروژه بودجه خاصی دریافت نکرد. E.L. توسط مؤسسات ملی بهداشت حمایت می‌شود: جایزه محقق میانه‌کار در تحقیقات با جهت‌گیری بیمار (K24AR075060) و کمک هزینه پروژه تحقیقاتی I.K. (R01AR082109). کمک‌های مالی تحقیقاتی از صندوق‌های تحقیقاتی رادیوم‌همت (009614) دریافت کرد و H.E. کمک‌های مالی از صندوق‌های تحقیقاتی رادیوم‌همت (211063, 181083)، منطقه استکهلم (FoUI-972654, FoUI-962339)، انجمن سرطان سوئد (210406JCIA01, 2111617Pj) و شورای تحقیقات سوئد (202201534) دریافت کرد. تأمین‌کنندگان مالی هیچ نقشی در طراحی مطالعه، جمع‌آوری داده، تحلیل و تفسیر داده‌ها یا نگارش این مقاله نداشتند.

مشارکت نویسندگان

JK و IK به طور مشترک به عنوان نویسندگان اول مشارکت داشتند. مفهوم و طراحی EL:، RD و IK جستجوی ادبیات، فرآیند غربالگری، استخراج داده و ارزیابی سوگیری IK:، JK و ZRC تحلیل و تفسیر داده‌ها JK:، AL و IK. EL. نگارش پیش‌نویس مقاله IK و JK بازنگری انتقادی برای محتوای فکری مهم و تأیید مقاله: همه نویسندگان. اخذ بودجه: EL، HE و IK نظارت EL و AL.

تضاد منافع

H.E. در نقش‌های مشاوره‌ای برای Novartis، BMS، GSK و Pierre Fabre خدمت کرده و ارائه‌هایی داشته است و بودجه تحقیقاتی حمایت‌شده از صنعت از SkylineDx دریافت کرده است. RD عضو کمیته هوش مصنوعی AAD و سردبیر وابسته در Journal of Investigative Dermatology است، هزینه‌های مشاوره‌ای از Pfizer، L'Oreal، Frazier Healthcare Partners دریافت کرده و گزینه‌های سهام در Revea و MDA Algorithms دارد. سایر نویسندگان هیچ تضاد منافی را اعلام نمی‌کنند.

اطلاعات تکمیلی

اطلاعات تکمیلی نسخه آنلاین حاوی مطالب تکمیلی در دسترس در <https://doi.org/10.1038/s41746-024-01031-w> است.

مکاتبات و درخواست‌ها برای مواد

مکاتبات و درخواست‌ها برای مواد باید به النی لینوس (Eleni Linos) ارسال شود.

اطلاعات تجدید چاپ و مجوزها

اطلاعات تجدید چاپ و مجوزها در <http://www.nature.com/reprints> در دسترس است.

یادداشت ناشر

Springer Nature در مورد ادعاهای قضایی در نقشه‌های منتشر شده و وابستگی‌های مؤسسات بی‌طرف باقی می‌ماند.

دسترسی آزاد

این مقاله تحت مجوز بین‌المللی Creative Commons Attribution 4.0 مجوز دارد که اجازه استفاده، اشتراک‌گذاری، سازگاری، توزیع و تولید مثل در هر رسانه یا قالب را می‌دهد، تا زمانی که اعتبار مناسب به نویسنده(های) اصلی و منبع داده شود، پیوندی به مجوز Creative Commons ارائه دهید و در صورت ایجاد تغییرات، آن را نشان دهید. تصاویر یا مطالب شخص ثالث دیگر در این مقاله در مجوز Creative Commons مقاله گنجانده شده‌اند، مگر اینکه خلاف آن در خط اعتبار به مطالب ذکر شده باشد. اگر ماده در مجوز Creative Commons مقاله گنجانده نشده باشد و استفاده مورد نظر شما طبق مقررات قانونی مجاز نباشد یا از استفاده مجاز فراتر رود، باید مستقیماً از دارنده حق چاپ اجازه بگیرید. برای مشاهده کپی این مجوز، به <http://creativecommons.org/licenses/by/4.0/> مراجعه کنید.

©نویسنده(ها) 2024