

ارزیابی مدل‌های پیش‌بینی هوش مصنوعی برای تشخیص سرطان پوست با استفاده از تصاویر درموسکوپي: چالش بزرگ همکاری بین‌المللی تصویربرداری پوست در سال ۲۰۱۹

مارک کامبالیا، نوتل کودلا، ورونیکا روتمبرگه کریستینا کاررو، استفن دوسا، دیوید گاتمن، برایان هلبو، هارالد کیتلر، نیکولاس آر کورتانسکی، کنستانس لیبیریس، مایکل ای. مارکتی، سباستیان پودلیپنیک، سوزانا پویگ، کریستف رینر، فیلیپ چاندل، یوخن وبر، آلن هالپرن، خوسپ مالو هی*

خلاصه

زمینه: مطالعات پیشین در مورد کاربرد هوش مصنوعی (AI) در درماتولوژی نشان داده‌اند که هوش مصنوعی از نظر دقت طبقه‌بندی تشخیصی، عملکرد بهتری نسبت به متخصصان درماتولوژی دارد. با این حال، این مطالعات به‌طور کافی سناریوهای واقعی بالینی را ارزیابی نکرده‌اند؛ مانند نحوه رفتار سیستم‌های هوش مصنوعی در مواجهه با تصاویر دسته‌های بیماری که در مجموعه داده‌های آموزشی گنجانده نشده‌اند یا تصاویری که از توزیع‌های آماری با جابجایی قابل توجه نسبت به توزیع‌های آموزشی گرفته شده‌اند. هدف ما شبیه‌سازی این سناریوهای دنیای واقعی و ارزیابی تأثیر مؤسسه منبع تصویر، تشخیص‌های خارج از مجموعه آموزشی و سایر آرتیفکت‌های تصویری بر دقت طبقه‌بندی بود تا به اطلاع‌رسانی به پزشکان و نهادهای نظارتی درباره ایمنی و دقت در دنیای واقعی کمک کنیم.

روش‌ها: ما یک چالش بزرگ طبقه‌بندی تصاویر درموسکوپي طراحی کردیم تا عملکرد الگوریتم‌های یادگیری ماشین را در کار طبقه‌بندی سرطان پوست از تصاویر درموسکوپي کمی کنیم و ببینیم این عملکرد چگونه تحت تأثیر جابجایی‌ها در توزیع آماری داده‌ها، دسته‌های بیماری که در مجموعه‌های داده آموزشی نمایندگی نشده‌اند، و آرتیفکت‌های تصویربرداری یا ضایعه قرار می‌گیرد. عواملی که ممکن است برای عملکرد مفید باشند، مانند فراداده‌های بالینی و داده‌های آموزشی خارجی جمع‌آوری شده توسط شرکت‌کنندگان چالش نیز ارزیابی شدند. ۲۵,۳۳۱ تصویر آموزشی جمع‌آوری شده از دو مجموعه داده (در وین [HAM10000] و بارسلون [BCN20000]) بین ۱ ژانویه ۲۰۰۰ تا ۳۱ دسامبر ۲۰۱۸، در هشت بیماری پوستی، در اختیار شرکت‌کنندگان چالش قرار گرفت تا الگوریتم‌های مناسب را طراحی کنند. سپس الگوریتم‌های آموزش‌دیده از نظر دقت متعادل در برابر مجموعه داده‌های آزمایشی HAM10000 و BCN20000 و داده‌های کشورهایی که در مجموعه آموزشی گنجانده نشده بودند (ترکیه، نیوزیلند، سوئد و آرژانتین) آزمایش شدند. مجموعه‌های داده آزمایشی حاوی تصاویر تمام دسته‌های تشخیصی موجود در آموزش به علاوه سایر تشخیص‌های گنجانده‌نشده در داده‌های آموزشی (دسته آموزش‌ندیده) بودند. ما عملکرد الگوریتم‌ها را در یک محیط شبیه‌سازی شده که منعکس‌کننده استفاده بالینی مورد نظر بود، با عملکرد ۱۸ متخصص درماتولوژی مقایسه کردیم.

یافته‌ها: ۶۴ تیم، ۱۲۹ پیش‌بینی الگوریتمی پیشرفته را روی یک مجموعه آزمایشی متشکل از ۸,۲۳۸ تصویر ارسال کردند. بهترین الگوریتم عملکردی، به‌طور متعادل دقت ۵۸.۸٪ را در داده‌های BCN20000 که برای بازتاب بهتر سناریوهای واقعی بالینی طراحی شده بود، به دست آورد. این در مقایسه با دقت متعادل ۸۲.۰٪ در HAM10000 بود که در یک معیار منتشر شده قبلی استفاده شده بود. جابجایی توزیع‌های آماری و دسته‌های بیماری گنجانده‌نشده در داده‌های آموزشی به کاهش دقت کمک کردند. آرتیفکت‌های تصویری از جمله مو، علامت‌های خودکار، زخم و مؤسسه منبع تصویر، دقت را به روشی پیچیده کاهش دادند که بر اساس تشخیص زمینه‌ای متفاوت بود. هنگام مقایسه الگوریتم‌ها با متخصصان درماتولوژی (۲۴۶۰ رتبه‌بندی روی ۱۲۶۹ تصویر)، الگوریتم‌ها در اکثر دسته‌ها بهتر از متخصصان عمل کردند، به استثنای کراتوز اکتینیک (دقت مشابه به طور متوسط) و تصاویر از دسته‌های گنجانده‌نشده در داده‌های آموزشی (۲۶٪ صحیح برای متخصصان در مقابل ۶٪ صحیح برای الگوریتم‌ها، $p < 0.0001$ برای ۲۵ الگوریتم برتر ارسالی، ۴۷.۱٪ از تصاویر متعلق به دسته‌های گنجانده‌نشده در داده‌های آموزشی، به اشتباه به عنوان تشخیص‌های بدخیم طبقه‌بندی شدند که در صورت استقرار بالینی فناوری‌های هوش مصنوعی فعلی پیشرفته، منجر به تعداد قابل توجهی بیوپسی غیرضروری می‌شد.

تفسیر: ما کمبودها و مسائل ایمنی خاصی را در سیستم‌های تشخیصی هوش مصنوعی برای سرطان پوست شناسایی کرده‌ایم که باید در پروتکل‌های ارزیابی تشخیصی آینده برای بهبود ایمنی و قابلیت اطمینان در عمل بالینی مورد توجه قرار گیرند.

تامین مالی: اتحاد تحقیقات ملانوما و لا ماراتو د. TV3

حق چاپ 2022 ©: نویسنده(گان). منتشر شده توسط الزویر. این یک مقاله دسترسی آزاد تحت مجوز CC BY-NC ND 4.0 است.

مقدمه

ملانوما در میان تمام سرطان‌های پوست، بالاترین نرخ مرگومیر را دارد و سالانه در مجموع حدود ۲۲۰,۰۰۰ مورد و ۳۷,۰۰۰ مرگ در ایالات متحده و اروپا گزارش می‌شود. تشخیص زودهنگام ملانوما و سایر تومورهای پوستی مهم‌ترین عامل پیش‌بینی‌کننده بقا است. تشخیص سرطان پوست نیاز به تخصص کافی و تجهیزات مناسب برای دقت کافی دارد. برای متخصصان درماتولوژی، دقت تشخیص ملانوما حدود ۷۱٪ با معاینه چشمی غیرمسلح و ۹۰٪ با استفاده از درماتوسکوپ است که یک لنز بزرگ‌کننده با فیلترهای امولسیون مایع یا قطبش متقاطع برای حذف بازتاب سطحی پوست است. با این حال، کمبود جهانی متخصص درماتولوژی وجود دارد: در اسپانیا به ازای هر ۱۰۰,۰۰۰ شهروند ۳.۲۷ متخصص درماتولوژی، در آلمان ۶.۶، در بریتانیا ۰.۵۵ و در ایالات متحده ۰.۳۳ وجود دارد. به دلیل این کمبود تخصص، تلاش‌ها بر مقیاس‌پذیری تخصص از طریق توسعه ابزارهای ارزیابی خودکار متمرکز شده است. بایگانی همکاری بین‌المللی تصویربرداری پوست (ISIC) بزرگترین مخزن عمومی مجموعه داده‌های تصویر درماتوسکوپی را برای حمایت از این تلاش تحقیقاتی مداوم گردآوری کرده است و پنج سال چالش عمومی برای استفاده از هوش مصنوعی (AI) برای تشخیص سرطان پوست را تسهیل کرده است. چندین مقاله گزارش توسعه سیستم‌های هوش مصنوعی با دقت تشخیصی بالاتر از متخصصان درماتولوژی در آزمایش‌های کنترل‌شده را داده‌اند. اگرچه پیشرفت فنی عظیمی حاصل شده است، هنوز کمبودهای مهمی وجود دارد که قبل از استقرار بالینی باید مورد توجه قرار گیرند. به عنوان مثال، مطالعات اعتبارسنجی خارجی با توزیع آماری جابجا شده که منعکس‌کننده واقعیت کاربرد بالینی است، حتی برای الگوریتم‌هایی که هم‌اکنون برای استفاده در عمل بالینی در دسترس هستند، انجام نشده است. علاوه بر این، سیستم‌های هوش مصنوعی فعلی قادر به اعلام آنچه که نمی‌دانند نیستند. به عنوان مثال، وقتی تصویری از یک بیماری که در داده‌های آموزشی نمایندگی نشده نشان داده می‌شود، سیستم نمی‌تواند آن را به عنوان دسته‌ای که روی آن آموزش ندیده علامت‌گذاری کند و در عوض آن را به عنوان یکی از شرایطی که برای شناسایی آموزش دیده طبقه‌بندی می‌کند. در نهایت، بیشتر کارهای قبلی در این موضوع شامل مطالعه عملکرد سیستم تنها بر روی داده‌های تصویری استاندارد یا بدون همبستگی با عملکرد متخصصان درماتولوژی بوده است. هدف ما ایجاد بزرگترین مجموعه داده عمومی در این حوزه، مجموعه داده BCN20000، برای طراحی چالش تشخیص سرطان پوست بود که به‌طور دقیق تأثیر عدم تعادل‌های آماری، تصاویر از دسته‌های آموزش‌ندیده (NT)، و داده‌های بالینی با کیفیت متغیر را بر عملکرد هوش مصنوعی ارزیابی کند و به ما امکان تحلیل تأثیر این عوامل بر عملکرد را بدهد. رویکرد چالش عمومی برای کاوش وضعیت فعلی پیشرفته‌ترین الگوریتم‌ها در تشخیص سرطان پوست از طریق هوش مصنوعی انتخاب شد. ما دقت (۱) روش‌های طبقه‌بندی پیشرفته روی مجموعه داده‌هایی که به طور خاص برای بازتاب بهتر واقعیت‌های بالینی نسبت به مطالعات قبلی طراحی شده بودند؛ (۲) الگوریتم‌هایی که به طور خاص برای شکست ایمن با علامت‌گذاری دسته‌های آموزش‌ندیده طراحی شده بودند؛ و (۳) الگوریتم‌ها در رابطه با ویژگی‌های غیرمعمول بالینی دنیای واقعی و سایر آرتیفکت‌های تصویربرداری، مانند تغییرات در شرایط نورپردازی، علامت‌گذاری‌های بالینی روی پوست، یا موی مسدودکننده دید ضایعه را بررسی کردیم. ما همچنین الگوریتم‌ها را در برابر متخصصان درماتولوژی آزمایش کردیم.

پژوهش در بافت

شواهد پیش از این مطالعه

ما در arXiv و PubMed Central برای مقالات منتشر شده به انگلیسی بین ۱ ژانویه ۲۰۰۲ و ۲۸ فوریه ۲۰۲۱، با استفاده از عبارت‌های جستجوی "تشخیص ملانوما" یا "شناسایی ملانوما" جستجو کردیم. جستجوی ما بیش از ۶۰,۰۰۰ مقاله را بازگرداند که ۳۰ مورد مرتبط با این موضوع بودند. برآورد خلاصه دقت الگوریتم‌های یادگیری ماشین گزارش شده برای شناسایی ملانوما به طور مداوم از سال ۲۰۱۸ از دقت متخصصان انسانی پیشی گرفته است. ما هیچ مطالعه‌ای نیافتیم که عملکرد الگوریتم را در طیف وسیعی از آرتیفکت‌های تصویری و مؤسسات منبع ارزیابی کرده باشد. اگرچه مطالعاتی بودند که عملکرد الگوریتم را بر روی کلاس‌های تشخیصی آموزش‌ندیده ارزیابی کردند، اما هیچ‌کدام به طور سیستماتیک خطاهایی که الگوریتم‌ها در تصاویر آموزش‌ندیده یا تصاویر دارای آرتیفکت مرتکب می‌شوند را ارزیابی نکرده بودند. ما بسیاری از مطالعاتی را یافتیم که در معرض سوگیری‌هایی مانند انتخاب و برچسب‌گذاری بودند و بسیاری داده‌های در دسترس عمومی را شامل نمی‌شدند.

ارزش افزوده این مطالعه

این مطالعه تحلیلی از الگوریتم‌های پیشرفته یادگیری عمیق ارائه می‌دهد. با استفاده از الگوریتم‌های ارسالی از طریق چالش بزرگ همکاری بین‌المللی تصویربرداری پوست ۲۰۱۹، ما تأثیر توزیع‌های آماری جایگزین داده‌ها (از طریق منابع تصویر مختلف)، دسته‌های بیماری نمایندگی‌نشده در مجموعه داده‌های آموزشی، آرتیفکت‌های تصویربرداری یا ضایعه، و عواملی که ممکن است برای عملکرد مفید باشند (مانند فراداده‌های بالینی و داده‌های آموزشی خارجی) را بر دقت تشخیصی ارزیابی کردیم. اگرچه الگوریتم‌ها در شناسایی ملانوما همچنان از خوانندگان متخصص بهتر عمل کردند، جابجایی توزیع‌های آماری و دسته‌های بیماری گنجانده‌نشده در داده‌های آموزشی به کاهش دقت الگوریتم کمک کردند. برای روش‌های خودکار، حدود ۵۰٪ از تصاویر متعلق به دسته‌های گنجانده‌نشده در داده‌های آموزشی، به اشتباه به عنوان تشخیص‌های بدخیم طبقه‌بندی شدند که در صورت استقرار بالینی منجر به تعداد قابل توجهی بیوپسی غیرضروری می‌شد.

پیامدهای تمام شواهد موجود

ما کمبودها و مسائل ایمنی خاصی را در سیستم‌های تشخیصی درماتولوژیک هوش مصنوعی شناسایی کرده‌ایم که باید قبل از اجرای بالینی در پروتکل‌های ارزیابی تشخیصی آینده برای بهبود ایمنی و قابلیت اطمینان مورد توجه قرار گیرند. این یافته‌ها شواهد موجود را پیش می‌برند زیرا تأثیر آرتیفکت‌های تصویر، مؤسسه منبع تصویر، و توزیع‌های آموزشی زمینه‌ای و کلاس‌های تشخیصی را بر عملکرد الگوریتم برجسته می‌کنند. این کار از تأمین مالی و پژوهش آینده متعهد به معیارسنجی دقیق و آزمون پیش از استقرار که سناریوهای بالینی را تقلید می‌کند، حمایت می‌کند.

روش‌ها

طرح مطالعه

ما یک چالش بزرگ طبقه‌بندی تصویر، چالش ISIC، برای کمی کردن عملکرد الگوریتم‌های یادگیری ماشین در کار طبقه‌بندی سرطان پوست از تصاویر درموسکوپی طراحی کردیم. چالش به صورت آنلاین با استفاده از پلتفرم Covalic میزبانی شد، جایی که شرکت‌کنندگان چالش می‌توانستند پیش‌بینی‌های تشخیصی الگوریتم خود را برای هر تصویر در مجموعه داده آزمایشی بارگذاری کنند. دعوت برای ارسال آثار از سراسر جهان درخواست شد؛ فراخوان ارسال از طریق ایمیل به مشترکین ISIC ارسال شد و چالش در رسانه‌های اجتماعی و کنفرانس‌های علمی تبلیغ شد. به شرکت‌کنندگان چالش اجازه داده شد تیم تشکیل دهند و مجاز به ارسال پیش‌بینی‌های تشخیصی از حداکثر سه الگوریتم متمایز بودند. ارسال‌های نامحدود برای هر الگوریتم مجاز بود، اما تنها آخرین ارسال نمره‌دهی می‌شد. جزئیات بیشتر چالش به صورت آنلاین در دسترس است.

ما چالش را به دو وظیفه تقسیم کردیم: (۱) طبقه‌بندی سرطان پوست از تصاویر درموسکوپی و (۲) طبقه‌بندی سرطان پوست از تصاویر درموسکوپی و فراداده. در هر دو وظیفه، الگوریتم‌ها از نظر توانایی تشخیص هشت دسته آموزش‌دیده، و

همچنین اینکه آیا قادر به شکست ایمن با شناسایی صحیح دسته‌های تشخیصی که روی آنها آموزش ندیده‌اند هستند یا خیر، آزمایش شدند. برای بهبود تکرارپذیری الگوریتم‌های موفق، از هر تیم در چالش خواسته شد یک مقاله مفصل حاوی روش‌های مورد استفاده برای طبقه‌بندی تصویر را ارسال کند. پروتکل مطالعه توسط هیئت‌های بازبینی اخلاق دانشگاه کوئینزلند، مرکز سرطان مموریال اسلون کترینگ، دانشگاه پزشکی وین و کلینیک بیمارستان بارسلون تأیید شد. در تمام مؤسسات مشارکت‌کننده، رضایت‌نامه آگاهانه کتبی برای تصاویر در موسکوپ جمع‌آوری شده گذشته‌نگر به دلیل ماهیت غیرشناسایی تصاویر توسط هیئت بازبینی اخلاق چشمپوشی شد.

مجموعه داده‌ها

تصاویر در موسکوپ ضایعات پوستی از کلینیک‌های نظارت بر سرطان پوست در سراسر جهان به دست آمد که عکس‌ها بین ۱ ژانویه ۲۰۰۰ تا ۳۱ دسامبر ۲۰۱۸ گرفته شده بودند. هر تصویر با فراداده‌هایی در مورد سن و جنسیت بیمار، محل آناتومیک ضایعه و یک شناسه ضایعه جفت شد. تصاویر متعدد گرفته‌شده از تجهیزات عکاسی مختلف یا در تاریخ‌های مختلف برای یک ضایعه معین مجاز بود که عمل بالینی واقعی را تقلید می‌کرد. ضایعات بین مجموعه‌های آموزشی و آزمایشی تقسیم شدند و توسط منبع و دسته تشخیصی در مجموعه داده آموزشی متعادل شدند.

مجموعه داده آموزشی حاوی ۲۵,۳۳۱ تصویر بود که از داده‌های دانشگاه پزشکی وین (HAM10000) و کلینیک بیمارستان بارسلون (BCN20000) تشکیل شده بود. به عنوان معیار برای یک چالش ISIC قبلی در سال ۲۰۱۸ استفاده شده بود. تمام مجموعه داده‌ها شامل برچسب‌هایی بودند که کلینیک دریافت‌کننده داده را مشخص می‌کرد که از این پس به عنوان مؤسسه منبع نامیده می‌شود.

یک مجموعه داده اعتبارسنجی مستقل و نامتعادل شامل ۱۰۰ تصویر در موسکوپ انتخاب‌شده تصادفی گرفته‌شده بین ۱ ژانویه ۲۰۰۰ تا ۳۱ دسامبر ۲۰۱۸ از دانشگاه پزشکی وین در اختیار شرکت‌کنندگان چالش قرار داشت. این تصاویر در مجموعه داده‌های آموزشی یا آزمایشی گنجانده نشده بودند و به شرکت‌کنندگان چالش برای اعتبارسنجی و اشکال‌زدایی ارسال‌های الگوریتمشان ارائه شدند، اما از مجموعه داده اعتبارسنجی برای ارزیابی یا ارزیابی‌های بیشتر استفاده نشد. مجموعه داده آزمایشی شامل ۸,۲۳۸ تصویر جمع‌آوری شده گذشته‌نگر از کلینیک بیمارستان بارسلون (BCN) و دانشگاه پزشکی وین (HAM) بود. تصاویری از ترکیه، نیوزیلند، سوئد و آرژانتین نیز گنجانده شد. تصاویر بیماران به صورت فردی از نظر قومیت، رنگ پوست یا ملیت برچسب‌گذاری نشده بودند. مجموعه داده آزمایشی شامل تمام دسته‌های تشخیصی موجود در آموزش، و همچنین سایر تشخیص‌های گنجانده‌نشده در داده‌های آموزشی بود که در یک دسته واحد به نام NT گروه‌بندی شدند. اگرچه داده‌های آزمایشی در مراکز جمع‌آوری شدند که داده‌های آموزشی را نیز ارائه کرده بودند، هیچ همپوشانی تصویر یا ضایعه‌ای بین مجموعه داده‌های آموزشی و آزمایشی وجود نداشت. جزئیات و توزیع‌های بیشتر مجموعه داده در پیوست (صفحه ۲) موجود است.


برچسب‌های تشخیصی

مجموعه داده‌های آموزشی و آزمایشی شامل تصاویر خال‌ها (نوی)، ملانوما، کراتوز خوش‌خیم، درماتوفیبروما، کارسینوم سلول بازال، کارسینوم سلول سنگفرشی شامل بیماری بون، ضایعات عروقی و کراتوز اکتینیک بودند. ضایعات ملانوسیتی مرزی حذف شدند. از شرکت‌کنندگان خواسته شد تصاویر آموزش‌ندیده را در مجموعه داده آزمایشی در یک دسته نهم به نام NT طبقه‌بندی کنند که به کلاس‌های تشخیصی گنجانده‌نشده در داده‌های آموزشی اشاره دارد. ما برچسب‌های تشخیصی حقیقی پایه را از طریق بازبینی آسیب‌شناسی بافتی برای تمام ضایعات بدخیم و بیوپسی شده و اجماع متفق‌القول متخصصان (حداقل سه متخصص تعریف‌شده به عنوان درماتولوژیست‌های دارای بورس از مرکز سرطان مموریال اسلون کترینگ، دانشگاه پزشکی وین یا کلینیک بیمارستان بارسلون؛ VR, CC, MAM, SPo, SPu, JM, PT و HK)، پایش دیجیتال، یا میکروسکوپ کانفوکال برای ضایعات خوش‌خیم بیوپسی‌نشده ایجاد کردیم. برای مجموعه داده BCN، ما این بازبینی‌ها را انجام دادیم. برای HAM، از داده‌های منتشر شده استفاده کردیم.

برچسب‌های اضافی

علاوه بر برچسب‌های ارائه‌شده به عنوان فراداده آموزشی و آزمایشی، ویژگی‌های جغرافیایی و مؤسسه منبع توسط پژوهشگران این مطالعه برای اهداف این تحلیل به دست آمد. مؤسسه منبع نمایانگر توزیع‌های آماری جایگزین و تفاوت‌های

اخذ عکس است. علاوه بر این، ویژگی‌های تصویربرداری کمی‌شده (مانند رنگدانه) و آرتیفکت‌های ضایعه (مانند وجود زخم، دلمه، رنگدانه، مو یا علامت خودکار) به صورت دستی حاشیه‌نویسی شدند. همکاران پژوهشی دانشجوی پزشکی حقوق‌بگیر در مرکز سرطان مموریال اسلون کترینگ و کلینیک بیمارستان بارسلون از نرم‌افزار حاشیه‌نویسی داخلی برای حاشیه‌نویسی وجود یا عدم وجود زخم، دلمه، رنگدانه، مو یا خودکار با استفاده از تکنیک‌های یادگیری فعال استفاده کردند. رنگدانه به عنوان یک رنگدانه قهوه‌ای در ناحیه ضایعه تعریف شد، دلمه به عنوان دلمه یا پوسته کراتینه روی ناحیه ضایعه تعریف شد و زخم یک نقص در سطح اپیدرمی (مانند فرسایش یا زخم) بود. مو به داشتن موهای کرکی یا انتهایی روی ضایعه مورد نظر تعریف شد و علامت‌های خودکار می‌توانست در هر نقطه از تصویر باشد.



ارزیابی الگوریتم

شرکت‌کنندگان چالش یک فایل ارزش جدا شده با ویرگول (CSV) حاوی پیش‌بینی‌های تشخیصی برای هر تصویر در مجموعه داده آزمایشی را به سیستم ارسال و نمردهی آنلاین (Covalic) ارسال کردند. میزان اطمینان تشخیص‌ها به صورت مقادیر اعشاری در بازه بسته (۰.۰، ۱.۰) بیان شد.

الگوریتم‌ها بر اساس دقت چندکلاسه متعادل (میانگین recall در کلاس‌ها پس از تصمیم‌گیری‌های طبقه‌بندی انحصاری متقابل) رتبه‌بندی شدند که مزیت متعادل کردن برای شیوع تشخیص‌های بدخیم، به ویژه ملانوما، در مقایسه با دقت استاندارد را دارد. عملکرد دقت متعادل الگوریتم‌ها بین زیرمجموعه‌های داده با استفاده از آزمون t جفت‌شده تعدیل‌شده با Bonferroni مقایسه شد. سطح معنی‌داری برای تمام آزمون‌های فرضیه ۰.۰۵ بود. از آزمون t جفتی Student استفاده شد زیرا الگوریتم‌ها روی همان تصاویر ارزیابی شدند. ماتریس سردرگمی و سطح زیر منحنی مشخصه عملیاتی گیرنده (AUROC) نیز محاسبه و با عوامل تصویربرداری و ضایعه که هر یک بر دقت تشخیصی تأثیر می‌گذارند (با استفاده از شناسه‌های الگوریتم به عنوان برجسب‌های گروه با یک ماتریس کوواریانس قابل تعویض) مقایسه شد. ماتریس‌ها به نه گروه تشخیصی برای هر حاشیه‌نویسی حقیقت پایه جدا شده‌اند، با آمار تجمعی نشان‌داده‌شده در ردیف اول هر گروه (ردیف مرجع)، و لایه‌بندی‌ها در ردیف‌های بعدی نشان داده شده‌اند. مقادیر ماتریس نشان‌دهنده نسبت تصاویر با برجسب‌های حقیقت پایه داده‌شده (مشخص‌شده توسط گروه) است که به طور متوسط در بین ۲۵ الگوریتم برتر، یک پیش‌بینی خاص توسط الگوریتم‌ها (مشخص‌شده توسط ستون‌ها) اختصاص داده شده است.

تحلیل‌های آماری با استفاده از بسته‌های پایتون pandas, matplotlib, scipy, numpy و statsmodels انجام شد.

مطالعه خواننده متخصص

ما عملکرد الگوریتم‌ها را در برابر عملکرد درماتولوژیست‌ها در یک محیط شبیه‌سازی شده که منعکس‌کننده استفاده بالینی مورد نظر بود مقایسه کردیم. ۱۸ متخصص درماتولوژیست دارای بورد از سراسر جهان (با حداقل ۲ سال استفاده فعال روزانه از درماتوسکوپ) تصاویر انتخاب‌شده از مجموعه‌ای از ۱۲۶۹ تصویر از مجموعه آزمایشی را طبقه‌بندی کردند. برای انجام ارزیابی، این متخصصان (از این پس خوانندگان متخصص نامیده می‌شوند) از یک پلتفرم سفارشی، DermaChallenge، ایجادشده توسط دانشگاه پزشکی وین استفاده کردند. خوانندگان متخصص ابتدا سه سطح آموزشی هر کدام ۳۰ تصویر از مجموعه داده آموزشی برای تمرین دریافت کردند، قبل از طبقه‌بندی تصاویر از نه دسته تشخیصی (شامل NT) در گروه‌های ۳۰ تصویری در یک زمان. برای مقایسه عملکرد بین خوانندگان متخصص و الگوریتم‌ها، از یک متریک خلاصه sAUROC استفاده شد که در R پیاده‌سازی شد.

نقش منبع تأمین مالی

تأمین‌کنندگان مالی مطالعه هیچ نقشی در طراحی مطالعه، جمع‌آوری داده، تحلیل داده، تفسیر داده یا نگارش گزارش نداشتند.

نتایج

۱۶۹ الگوریتم توسط ۶۴ تیم ارسال شد که به وظیفه فقط تصویر (۱۲۹ ارسال از ۶۴ تیم) و وظیفه ترکیبی تصویر و فراداده (۴۰ ارسال از ۱۶ تیم) تقسیم شدند. دو الگوریتم برتر عملکردی از معماری EfficientNet و تیم سوم از معماری ResNet استفاده کردند. بهترین الگوریتم عملکردی به دقت متعادل کلی ۶۳.۶٪ دست یافت.

		NV									BKL									MEL								
Artifacts	Ref	0.81	0.033	0.08	0.0039	0.01	0.033	0.0015	0.0077	0.018	0.068	0.55	0.11	0.025	0.1	0.08	0.0023	0.011	0.052	0.14	0.04	0.7	0.0079	0.039	0.037	0.0076	0.0053	0.028
	No crust	0.82	0.03	0.08	0.003	0.01	0.032	0.0015	0.0076	0.017	0.073	0.55	0.12	0.02	0.1	0.078	0.0022	0.012	0.05	0.14	0.04	0.7	0.008	0.039	0.037	0.0077	0.0054	0.028
	Crust	0.35	0.24	0.11	0.061	0.039	0.11	0	0.018	0.081	0.01	0.53	0.054	0.083	0.13	0.1	0.0032	0.0032	0.08	0.016	0.019	0.83	0.0024	0.052	0.054	0	0	0.024
	No hair	0.82	0.027	0.08	0.0033	0.01	0.031	0.0015	0.0081	0.017	0.069	0.53	0.11	0.025	0.11	0.088	0.0027	0.012	0.053	0.14	0.038	0.7	0.0083	0.044	0.032	0.0064	0.0055	0.028
	Hair	0.78	0.052	0.079	0.0054	0.01	0.039	0.0014	0.0067	0.023	0.062	0.63	0.13	0.024	0.057	0.037	0	0.0038	0.048	0.15	0.052	0.67	0.0059	0.011	0.067	0.015	0.004	0.027
	No pen	0.82	0.031	0.076	0.004	0.011	0.03	0.0015	0.0073	0.016	0.064	0.57	0.11	0.023	0.1	0.077	0.0025	0.0085	0.05	0.13	0.039	0.71	0.0083	0.039	0.033	0.008	0.0054	0.026
	Pen	0.76	0.043	0.098	0.003	0.0095	0.047	0.0011	0.0099	0.03	0.098	0.41	0.13	0.038	0.13	0.1	0.0005	0.029	0.07	0.23	0.048	0.53	0.0024	0.037	0.098	0.002	0.0039	0.05
	No pigmentation	0.35	0.089	0.031	0.065	0.063	0.24	0.012	0.044	0.099	0.035	0.33	0.029	0.057	0.19	0.2	0.013	0.013	0.13	0.0075	0.018	0.46	0.045	0.046	0.27	0.075	0.0069	0.073
	Pigmentation	0.83	0.032	0.082	0.0019	0.0088	0.026	0.0011	0.0066	0.016	0.072	0.58	0.12	0.021	0.092	0.063	0.0008	0.011	0.042	0.15	0.041	0.71	0.0056	0.039	0.022	0.0032	0.0052	0.025
	No ulceration	0.81	0.033	0.08	0.0039	0.01	0.033	0.0015	0.0078	0.018	0.069	0.54	0.11	0.025	0.11	0.079	0.0012	0.011	0.052	0.16	0.043	0.69	0.0053	0.042	0.024	0.005	0.0057	0.027
	Ulceration	0.38	0	0.6	0	0	0	0	0	0.02	0.062	0.66	0.058	0.015	0.015	0.098	0.052	0.0062	0.089	0.0014	0.013	0.74	0.028	0.02	0.13	0.027	0.0022	0.037
Anatomical site	Torso	0.84	0.024	0.087	0.0024	0.0027	0.028	0.0013	0.0053	0.013	0.11	0.57	0.18	0.017	0.028	0.09	0.0033	0.0068	0.052	0.21	0.016	0.69	0.004	0.0076	0.027	0.012	0.0034	0.022
	Head or neck	0.34	0.15	0.12	0.031	0.1	0.16	0.0010	0.0054	0.078	0.022	0.52	0.1	0.0057	0.23	0.057	0.0006	0.0014	0.053	0.021	0.089	0.64	0.0035	0.15	0.059	0.0002	0	0.032
	Lower extremity	0.95	0.031	0.074	0.0002	0.0014	0.01	0.002	0.017	0.014	0.075	0.48	0.08	0.085	0.041	0.11	0.0017	0.044	0.075	0.17	0.022	0.73	0.011	0.0043	0.019	0.0021	0.016	0.019
	Upper extremity	0.81	0.027	0.065	0.0061	0.0089	0.043	0.0009	0.012	0.024	0.072	0.43	0.072	0.057	0.098	0.19	0.0033	0.02	0.054	0.13	0.057	0.67	0.015	0.022	0.051	0.01	0.0053	0.046
	Palms or soles	0.72	0.0029	0.19	0	0.0044	0.041	0.011	0.0065	0.023	0.08	0.56	0.28	0	0	0	0	0	0.08	0.079	0.025	0.8	0.017	0.012	0.016	0.018	0.0003	0.032
	Oral or genital																											
Source institution	s_BCN	0.74	0.043	0.11	0.0044	0.017	0.049	0.002	0.01	0.026	0.074	0.42	0.13	0.029	0.15	0.11	0.0026	0.013	0.07	0.13	0.039	0.7	0.0079	0.044	0.042	0.0067	0.0053	0.03
	s_HAM_external	0.92	0.029	0.038	0	0	0.0027	0	0.0007	0.005	0.064	0.8	0.053	0.0066	0.034	0.016	0.003	0.002	0.021	0.2	0.01	0.75	0.0013	0	0.0013	0.0025	0.011	0.021
	s_HAM_rosendahl	0.73	0.046	0.11	0.029	0.0027	0.041	0	0.013	0.029	0.03	0.75	0.089	0.047	0.019	0.035	0	0.01	0.022	0.13	0.1	0.68	0.024	0.025	0.0073	0	0.0073	0.028
	s_HAM_modern	0.88	0.033	0.059	0.0004	0.0005	0.009	0.0018	0.003	0.0086	0.083	0.78	0.1	0.0034	0	0.0088	0.0014	0.0068	0.018	0.22	0.022	0.71	0.001	0.0015	0.0065	0.026	0.001	0.012
	s_HAM_molemax	0.99	0.0025	0.0002	0.0002	0	0.0001	0.0004	0.0025	0.0005	0.022	0.94	0	0.008	0.01	0	0.002	0.012	0.008	1	0	0	0	0	0	0	0	0
	s_HAM_vienna_dias	0.9	0.013	0.075	0	0	0	0	0	0.011										0	0	1	0	0	0	0	0	0
		NV-NV	NV-BKL	NV-MEL	NV-SCC	NV-AK	NV-BCC	NV-VASC	NV-DF	NV-NT	BKL-NV	BKL-BKL	BKL-MEL	BKL-SCC	BKL-AK	BKL-BCC	BKL-VASC	BKL-DF	BKL-NT	MEL-NV	MEL-BKL	MEL-MEL	MEL-SCC	MEL-AK	MEL-BCC	MEL-VASC	MEL-DF	MEL-NT

		SCC								AK								BCC										
Artifacts	Ref	0.0089	0.096	0.048	0.48	0.084	0.19	0.0031	0.0099	0.081	0.015	0.16	0.062	0.033	0.51	0.15	0.0004	0.0026	0.069	0.017	0.033	0.017	0.02	0.049	0.82	0.0036	0.008	0.037
	No crust	0.012	0.1	0.067	0.48	0.07	0.19	0.0026	0.0055	0.08	0.016	0.17	0.065	0.024	0.52	0.14	0.0004	0.0027	0.07	0.02	0.035	0.019	0.017	0.043	0.82	0.004	0.0092	0.037
	Crust	0.00083	0.086	0.0042	0.49	0.12	0.19	0.0042	0.02	0.083	0	0.027	0.021	0.15	0.47	0.28	0.0014	0.0014	0.051	0.0037	0.023	0.008	0.032	0.075	0.81	0.0015	0.0017	0.041
	No hair	0.0073	0.11	0.053	0.46	0.086	0.19	0.0036	0.0061	0.083	0.015	0.16	0.072	0.02	0.56	0.12	0.0006	0.0024	0.058	0.012	0.031	0.017	0.02	0.054	0.82	0.0038	0.0079	0.038
	Hair	0.018	0.046	0.022	0.57	0.07	0.17	0	0.03	0.072	0.016	0.17	0.03	0.073	0.36	0.24	0	0.0032	0.1	0.042	0.043	0.02	0.017	0.023	0.81	0.0028	0.0083	0.035
	No pen	0.0094	0.091	0.05	0.5	0.086	0.17	0.0024	0.01	0.081	0.012	0.13	0.1	0.057	0.53	0.13	0.0002	0.0033	0.045	0.0077	0.017	0.018	0.023	0.046	0.84	0.004	0.0088	0.033
	Pen	0	0.19	0	0.08	0.04	0.58	0.015	0.005	0.085	0.018	0.2	0.014	0.0038	0.5	0.17	0.0007	0.0016	0.098	0.038	0.069	0.017	0.013	0.054	0.75	0.0027	0.006	0.048
	No pigmentation	0.0027	0.11	0.012	0.48	0.049	0.24	0.0047	0.011	0.084	0.004	0.049	0.004	0.07	0.48	0.31	0	0.003	0.082	0.0082	0.023	0.01	0.031	0.068	0.8	0.004	0.0088	0.048
	Pigmentation	0.02	0.06	0.11	0.49	0.15	0.086	0	0.0073	0.076	0.018	0.19	0.078	0.023	0.57	0.1	0.0005	0.0024	0.065	0.025	0.041	0.024	0.01	0.031	0.83	0.0032	0.0073	0.028
	No ulceration	0.012	0.094	0.048	0.5	0.11	0.14	0.0018	0.012	0.075	0.016	0.16	0.063	0.03	0.52	0.14	0.0004	0.0027	0.069	0.019	0.033	0.014	0.016	0.048	0.82	0.0039	0.0088	0.037
	Ulceration	0.0017	0.1	0.048	0.43	0.016	0.3	0.0058	0.0042	0.094	0	0.073	0.017	0.11	0.27	0.45	0	0	0.08	0.0029	0.034	0.046	0.046	0.052	0.78	0.0015	0.0018	0.039
Anatomical site	Torso	0.01	0.095	0.012	0.51	0.056	0.22	0.007	0.0052	0.082	0.04	0.24	0.14	0.056	0.18	0.28	0	0.0031	0.059	0.021	0.028	0.015	0.0097	0.024	0.87	0.0064	0.0038	0.026
	Head or neck	0.0061	0.094	0.096	0.34	0.17	0.22	0	0.0009	0.078	0.011	0.16	0.054	0.0057	0.58	0.12	0.0004	0.0026	0.067	0.016	0.039	0.022	0.013	0.082	0.78	0.0038	0.0024	0.044
	Lower extremity	0.0017	0.11	0.037	0.66	0.015	0.097	0	0.005	0.083	0	0.16	0	0.04	0.6	0.2	0	0	0	0.012	0.038	0.0066	0.057	0.078	0.71	0.0007	0.0042	0.06
	Upper extremity	0.03	0.027	0.12	0.57	0.02	0.16	0	0.017	0.053	0.036	0.044	0.046	0.4	0.065	0.32	0.0021	0.0021	0.082	0.0054	0.033	0.0078	0.041	0.026	0.85	0	0.0029	0.032
	Palms or soles	0	0.09	0	0.54	0.01	0	0	0.21	0.15										0	0.0044	0.04	0.022	0.2	0.62	0	0.0044	0.12
	Oral or genital																											
Source institution	s_BCN	0.0045	0.098	0.039	0.46	0.079	0.22	0.0036	0.011	0.085	0.016	0.16	0.059	0.026	0.51	0.15	0.0005	0.0024	0.071	0.017	0.032	0.016	0.02	0.053	0.81	0.0038	0.0081	0.039
	s_HAM_external										0.027	0.027	0.053	0.24	0.61	0	0	0	0.04	0.038	0.017	0.069	0.0036	0.0036	0.84	0.0036	0.0012	0.028
	s_HAM_rosendahl	0.02	0.093	0.038	0.63	0.12	0.036	0	0.0073	0.056	0	0.065	0.092	0.18	0.62	0.0062	0	0.0092	0.022	0.0055	0.032	0.0083	0.041	0.0055	0.87	0	0.018	0.017
	s_HAM_modern	0.18	0	0.72	0	0	0	0	0	0.1	0	0.19	0.25	0	0.56	0	0	0	0	0.04	0.068	0.012	0.0053	0.0027	0.89	0	0.0027	0.015
	s_HAM_molemax																											
s_HAM_vienna_dias																												
		SCC-NV	SCC-BEL	SCC-MELIS	CC-SCC	SCC-AK	SCC-SBRC	CC-VASC	SCC-DF	SCC-NIT	AK-NV	AK-BEL	AK-MEL	AK-SCC	AK-AK	AK-BCC	AK-VASC	AK-DF	AK-NIT	BCC-NV	BCC-BEL	BCC-MELIS	CC-SBCC	BCC-AK	BCC-BCC	CC-VASC	BCC-DF	BCC-NIT

C		VASC										DF										NT									
		Ref	0.04	0.018	0.075	0.038	0.0051	0.17	0.6	0.011	0.047	0.08	0.02	0.016	0.028	0.026	0.086	0.0022	0.47	0.07	0.078	0.09	0.078	0.069	0.15	0.32	0.042	0.057	0.11		
Artifacts	No crust	0.042	0.015	0.079	0.031	0.005	0.17	0.61	0.011	0.042	0.085	0.022	0.01	0.032	0.025	0.073	0.0025	0.69	0.058	0.083	0.081	0.085	0.06	0.15	0.33	0.047	0.056	0.11			
	Crust	0	0.08	0.008	0.17	0.008	0.26	0.34	0.008	0.14	0.04	0.004	0.068	0	0.036	0.19	0	0.49	0.17	0.056	0.14	0.038	0.11	0.19	0.28	0.015	0.064	0.11			
	No hair	0.047	0.022	0.099	0.049	0.0068	0.11	0.6	0.014	0.057	0.05	0.016	0.019	0.025	0.017	0.083	0.0012	0.73	0.061	0.069	0.08	0.092	0.066	0.16	0.32	0.046	0.057	0.11			
	Hair	0.015	0.0033	0	0	0	0.37	0.6	0	0.015	0.18	0.036	0.0095	0.038	0.055	0.097	0.0057	0.48	0.099	0.11	0.13	0.025	0.078	0.13	0.33	0.028	0.059	0.11			
	No pen	0.043	0.019	0.061	0.04	0.0055	0.18	0.59	0.011	0.049	0.088	0.02	0.018	0.029	0.025	0.084	0.0025	0.66	0.071	0.079	0.085	0.078	0.07	0.16	0.32	0.043	0.059	0.11			
	Pen	0	0	0.27	0	0	0.1	0.62	0	0.011	0.012	0.024	0	0.016	0.036	0.11	0	0.74	0.06	0.067	0.23	0.068	0.027	0.12	0.31	0.034	0.016	0.13			
	No pigmentation	0.012	0.0051	0.085	0.023	0.0056	0.2	0.62	0.014	0.025	0.044	0.018	0.0044	0.039	0.058	0.21	0.003	0.54	0.084	0.072	0.056	0.059	0.085	0.15	0.36	0.05	0.05	0.12			
	Pigmentation	0.11	0.048	0.053	0.073	0.004	0.097	0.54	0.004	0.075	0.095	0.022	0.022	0.023	0.012	0.033	0.0019	0.73	0.064	0.091	0.16	0.12	0.032	0.16	0.25	0.026	0.074	0.089			
	No ulceration	0.055	0.02	0.045	0.022	0.0029	0.2	0.6	0.015	0.046	0.08	0.02	0.016	0.028	0.026	0.086	0.0022	0.47	0.07	0.086	0.09	0.059	0.059	0.16	0.34	0.036	0.064	0.11			
Ulceration	0.0085	0.013	0.14	0.069	0.0097	0.12	0.6	0.0012	0.047	0.021	0	0	0	0	0	0	1	0	0.021	0.094	0.22	0.15	0.081	0.24	0.09	0.0074	0.099				
Anatomical site	Torso	0.12	0	0.0021	0	0	0.029	0.83	0.0021	0.013	0	0	0	0	0	0	0	1	0	0.073	0.1	0.03	0.051	0.095	0.44	0.05	0.067	0.098			
	Head or neck	0.015	0	0.0084	0.029	0.0042	0.71	0.2	0	0.038	0	0	0	0	0.18	0.1	0	0.6	0.12	0.042	0.077	0.05	0.036	0.28	0.4	0.0081	0.01	0.096			
	Lower extremity	0.008	0.038	0.046	0.16	0.014	0.084	0.57	0.002	0.086	0.015	0.018	0	0.068	0.0069	0.087	0	0.77	0.036	0.094	0.13	0.064	0.13	0.074	0.24	0.051	0.11	0.11			
	Upper extremity	0.0073	0.073	0.16	0.011	0.015	0.11	0.47	0.029	0.13	0.091	0.019	0.05	0.018	0.07	0.2	0.008	0.38	0.17	0.095	0.065	0.12	0.053	0.12	0.24	0.1	0.091	0.11			
	Palms or soles	0.016	0	0.78	0	0	0	0.18	0	0.024	0.15	0.028	0.23	0.13	0.08	0.065	0.093	0.024	0.2	0.15	0.028	0.23	0.13	0.08	0.065	0.093	0.024	0.2			
	Oral or genital	0.016	0	0.78	0	0	0	0.18	0	0.024	0.15	0.028	0.23	0.13	0.08	0.065	0.093	0.024	0.2	0.15	0.028	0.23	0.13	0.08	0.065	0.093	0.024	0.2			
Source institution	s_BCN	0.043	0.024	0.11	0.058	0.0079	0.25	0.43	0.0061	0.064	0.055	0.022	0.023	0.023	0.05	0.15	0.0043	0.57	0.11	0.078	0.09	0.078	0.069	0.15	0.32	0.042	0.057	0.11			
	s_HAM_external	0.06	0.013	0.016	0	0	0.024	0.82	0.038	0.024	0.14	0.027	0.0077	0.0039	0	0	0	0.79	0.028	0.073	0.1	0.03	0.051	0.095	0.44	0.05	0.067	0.098			
	s_HAM_rosendahl	0.008	0.038	0.046	0.16	0.014	0.084	0.57	0.002	0.086	0.015	0.018	0	0.068	0.0069	0.087	0	0.77	0.036	0.094	0.13	0.064	0.13	0.074	0.24	0.051	0.11	0.11			
	s_HAM_modern	0	0	0	0	0	0	0.99	0	0.0089	0.005	0	0.015	0.12	0	0.12	0	0	0.71	0.042	0.095	0.065	0.12	0.053	0.12	0.24	0.1	0.091	0.11		
	s_HAM_molemar	0.01	0	0	0	0	0	0.99	0	0	0	0	0	0	0	0	0	0	0.99	0.01	0.15	0.028	0.23	0.13	0.08	0.065	0.093	0.024	0.2		
	s_HAM_vienna_dias	0.01	0	0	0	0	0	0.99	0	0	0	0	0	0	0	0	0	0	0.99	0.01	0.15	0.028	0.23	0.13	0.08	0.065	0.093	0.024	0.2		
		VASC-W	VASC-WL	VASC-MEL	VASC-SEC	VASC-AK	VASC-BCC	VASC-VASC	VASC-DF	VASC-NT	DF-W	DF-MEL	DF-MEL	DF-SEC	DF-AK	DF-BCC	DF-VASC	DF-DF	DF-NT	NT-W	NT-MEL	NT-MEL	NT-SEC	NT-AK	NT-BCC	NT-VASC	NT-DF	NT-NT			

دقت متعادل الگوریتم بر روی بخش مجموعه داده - HAM که یک معیار اولیه کمتر بازتاب‌دهنده تغییرات کیفیت تصویر مشاهده‌شده در عمل است - به طور قابل توجهی بهتر از تصاویر BCN بود، حتی بدون در نظر گرفتن تأثیر دسته NT، که همه الگوریتم‌ها روی آن عملکرد ضعیفی داشتند (شکل ۱). دقت متعادل بهترین الگوریتم هنگام مقایسه مجموعه داده HAM با تصاویر جدید در BCN (۲۳.۲٪ از ۸۲.۰٪ به ۵۸.۸٪) کاهش یافت. برای میانگین AUROC، این کاهش ۰.۰۷۵ (از ۰.۹۸۱ در HAM به ۰.۹۰۷ در BCN) بود. در تمام الگوریتم‌ها، میانگین کاهش دقت متعادل بین بخش‌های مجموعه داده ۲۲.۳٪ (انحراف معیار ۸.۶؛ $p < 0.0001$) بود.

استفاده از فراداده کمی (مانند محل آناتومیک ضایعه، جنسیت و سن بیمار) میانگین دقت الگوریتم را اندکی از ۵۰٪ (SD ۱۵) به ۵۶٪ (SD ۷) بهبود بخشید (شکل ۱).

در تمام روش‌ها، توانایی الگوریتم‌ها در علامت‌گذاری دسته NT نسبت به توانایی آن‌ها در طبقه‌بندی تشخیص‌های گنجاندن‌شده در داده‌های آموزشی مختل شد (شکل ۲). به طور متوسط در بین ۲۵ تیم برتر، تنها ۱۱٪ از پیش‌بینی‌های NT صحیح بودند که مشابه شانس تصادفی (۱ از ۹) بود. بیشتر وضعیت‌های بیماری NT خوش‌خیم به اشتباه به عنوان کارسینوم سلول بازال طبقه‌بندی شدند (۳۲.۴٪) به طور متوسط در بین ۲۵ الگوریتم برتر)، با ۷.۸٪ دیگر به اشتباه به عنوان ملانوما، و ۶.۹٪ دیگر به اشتباه به عنوان کارسینوم سلول سنگفرشی طبقه‌بندی شدند.

تیم برتر عملکردی به دسته NT با آموزش یک مدل روی داده‌های خارجی که خودشان به دست آورده بودند، از جمله پوست سالم، زگیل، کیست و تغییرات خوش‌خیم نزدیک شد. رویکردهای دیگر مورد استفاده شرکت‌کنندگان چالش شامل مدل‌های مستقیم ۸ کلاسه که اجازه نمی‌داد تصویر به هیچ کلاسی تعلق داشته باشد، و برآورد آنتروپی شانون بود. علیرغم این تلاش‌ها، بهترین الگوریتم تنها ۱.۶٪ از دسته NT را به درستی تخمین زد (پیوست صفحه ۶).

یک ماتریس سردرگمی به عنوان تابعی از تشخیص برای ۲۵ الگوریتم برتر (به طور اضافی لایه‌بندی شده بر اساس آرتیفکت‌های تصویر، محل آناتومیک و مؤسسه منبع) در شکل ۲ نشان داده شده است. نمایش نسبی هر دسته در پیوست (صفحه ۳) ارائه شده است.

شکل ۱: دقت الگوریتم در تمام ارسال‌ها، بر اساس مجموعه داده، استفاده از فراداده و کلاس تشخیصی

(A) نمودار جعبه‌ای و جدول نشان‌دهنده میانه (IQR) برای دقت متعادل در تمام ارسال‌های شرکت‌کنندگان برای هر بخش مجموعه داده آزمایشی ($p < 0.001$) برای تمام مقایسه‌ها (B). (نمودار جعبه‌ای دقت‌های متعادل خاص تشخیص برای هر کلاس تشخیصی (C). مقایسه دقت متعادل در تمام ارسال‌ها با و بدون فراداده بالینی.

AK=اکرتوز اکتینیک، BCC=کارسینوم سلول بازال، BCN=کلینیک بیمارستان بارسلون، BKL=کراتوز خوش‌خیم. DF=درماتوفیبروما، HAM=دانشگاه پزشکی وین، MEL=ملانوما، NT=آموزش‌ندیده، NV=خال (نوی). SCC=کارسینوم سلول سنگفرشی، VASC=ضایعات عروقی.

تأثیر آرتیفکت‌های تصویر کمی‌شده (مانند دلمه، مو یا علامت خودکار) بر دقت تشخیصی در ردیف‌های بعدی شکل ۲ در بین ۲۵ الگوریتم برتر نشان داده شده است. تشخیص‌هایی که مکرراً با دلمه ظاهر نمی‌شوند (مانند ضایعات عروقی، درماتوفیبروما و خال‌ها) اغلب هنگامی که دلمه وجود داشت توسط الگوریتم‌ها به اشتباه دسته‌بندی شدند. وجود مو بر دسته‌بندی اشتباه تأثیر نگذاشت؛ به جز کراتوز اکتینیک، که تنها ۳۶٪ از کراتوز‌های اکتینیک با موی موجود در تصویر به درستی طبقه‌بندی شدند (در مقابل ۵۶٪ بدون مو). به طور معمول، ضایعات رنگدانه‌دار، مانند خال‌ها و ملانوما، هنگامی که فاقد رنگدانه بودند اغلب به اشتباه به عنوان کارسینوم سلول بازال طبقه‌بندی شدند (به ترتیب ۲۴٪ و ۲۷٪ از مواقع). ضایعات رنگدانه‌دار معمولی، مانند خال‌ها (۸۳٪ صحیح هنگام رنگدانه‌دار) و ملانوما (۷۱٪ صحیح هنگام رنگدانه‌دار)، هنگامی که فاقد رنگدانه بودند دقت کاهش‌یافته‌ای داشتند (۳۵٪ برای خال‌ها و ۴۶٪ برای ملانوما). هنگامی که فاقد رنگدانه بودند، خال‌ها و ملانوما اغلب به اشتباه به عنوان کارسینوم سلول بازال طبقه‌بندی شدند (به ترتیب ۲۴٪ و ۲۷٪ از مواقع). هنگامی که تأثیر محل آناتومیک بر عملکرد الگوریتم را اندازه‌گیری کردیم، ضایعات از نواحی آناتومیک سر و گردن اغلب در بین خال‌ها، تکثیرهای عروقی و درماتوفیبروما به اشتباه دسته‌بندی شدند. این یافته می‌تواند نتیجه تفاوت در الگوهای درموسکوپی روی پوست ناشی از آسیب مزمن آفتاب به دلیل قرارگیری در مناطق در معرض آفتاب بدن باشد. در مورد تأثیر مؤسسات منبع تصویر مختلف، ۲۵ الگوریتم برتر ۹۹.۰٪ از خال‌ها را از منبع s_HAM_molemax به درستی تشخیص دادند؛ با این حال، هیچ الگوریتمی ملانوما را از همان منبع به درستی شناسایی نکرد. به طور متوسط، ۲۵ الگوریتم برتر ۷۵.۰٪ از ملانوماها را از منبع s_HAM_external به درستی شناسایی کردند. این اختلاف در عملکرد تشخیصی بین منابع تصویر احتمالاً منعکس‌کننده توزیع‌های زمینه‌ای متفاوت ملانوما و خال‌ها در مجموعه داده‌ها است (پیوست صفحه ۳).

دسته NT برای تحلیل به پنج زیردسته تقسیم شد، از جمله اسکار، نئوپلاسم خوش‌خیم (مانند اونیکوماتریکوما)، واریانت نرمال (شامل هایپرپیگمنتاسیون و هیپوملانوزیس)، بیماری التهابی (شامل اگزما و پسوریازیس) و بیماری عفونی (پیوست صفحه ۳). شکل ۳ یک ماتریس سردرگمی بین این زیردسته‌ها و سایر دسته‌های تشخیصی گنجانده‌شده در داده‌های آموزشی، به طور متوسط در بین ۲۵ الگوریتم برتر ارائه می‌دهد. ضایعاتی که عمدتاً صورتی هستند، مانند اسکارها، ضایعات التهابی و نئوپلاسم‌های خوش‌خیم، معمولاً به اشتباه به عنوان کارسینوم سلول بازال (که آن‌ها نیز به رنگ صورتی هستند) تشخیص داده شدند.

شکل ۲: ماتریس سردرگمی، جدا شده به نه گروه برای هر دسته تشخیصی در مجموعه آزمایشی
مقادیر نشان‌دهنده نسبت تصاویر در مجموعه آزمایشی هستند که یک طبقه‌بندی مشخص‌شده توسط ستون‌ها به آن‌ها داده شده است، به طور متوسط برای ۲۵ الگوریتم برتر. ردیف مرجع هر گروه مقادیر تجمعی برای هر تشخیص را نشان می‌دهد. ردیف‌های بعدی شامل لایه‌بندی در آرتیفکت‌ها (یعنی دلمه، مو، علامت خودکار)، محل آناتومیک و مؤسسه منبع هستند. اندام فوقانی به بازوها و پاها (نه کف دست یا پا) اشاره دارد. اندام تحتانی به پاها (نه کف دست یا پا) اشاره دارد.

ما از یک پلتفرم خواننده تعاملی آنلاین (DermaChallenge) برای ارزیابی عملکرد تشخیصی خوانندگان متخصص در مقایسه با ارسال‌های الگوریتم استفاده کردیم. ۸۲ آزمون از ۳۰ تصویر انجام شد (توزیع پایه، جدول ۱)، که هر کدام منعکس‌کننده توزیع کلی در مجموعه آزمایشی بود. این توزیع در زمان مطالعه برای خوانندگان متخصص شناخته شده نبود. ما ۲۴۶۰ رتبه‌بندی روی ۱۲۶۹ تصویر در دوره‌های ۳۰ تصویری دریافت کردیم (جدول ۲، شکل ۴). تحلیل منحنی مشخصه عملیاتی گیرنده نشان داد که عملکرد سه الگوریتم برتر برای بدخیمی برتر از خوانندگان متخصص بود، به استثنای دسته NT (شکل ۴). بهترین متخصصان همچنان برای بدخیمی از سه الگوریتم برتر بهتر عمل کردند؛ با این حال، به طور متوسط، متخصصان از سه الگوریتم برتر بهتر عمل نکردند. برای تشخیص کراتوز اکتینیک، خوانندگان متخصص دقت پایین‌تری نسبت به سه الگوریتم برتر نشان دادند (۴۳٪ در مقابل ۸۳٪) اما به طور مشابه (۴۳٪ در مقابل ۴۴٪) با الگوریتم‌ها به طور متوسط عمل کردند (جدول ۲). سه الگوریتم برتر دقت تشخیصی بهتری نسبت به خوانندگان متخصص در مورد کارسینوم سلول بازال (۹۱٪ در مقابل ۷۰٪)، درماتوفیبروما (۷۳٪ در مقابل ۵۰٪) و خال‌ها (۷۶٪ در مقابل ۵۶٪) داشتند. اگرچه دسته NT برای متخصصان و الگوریتم‌ها چالش‌برانگیز بود، خوانندگان متخصص به طور قابل

توجهی بهتر از تمام الگوریتم‌ها از نظر حساسیت و خلاصه AUROC عمل کردند (۲۶٪ طبقه‌بندی صحیح در مقابل ۶٪، $p < 0.0001$).

	NV	BKL	MEL	SCC	AK	BCC	VASC	DF	NT
Inflammatory disease	0-055	0-072	0-025	0-095	0-19	0-36	0-02	0-081	0-10
Benign neoplasm	0-096	0-12	0-059	0-053	0-13	0-28	0-072	0-073	0-11
Normal variant	0-13	0-089	0-31	0-086	0-07	0-13	0-049	0-015	0-12
Scar	0-029	0-055	0-082	0-048	0-19	0-44	0-019	0-033	0-10
Infectious disease	0-16	0-18	0-074	0-11	0-065	0-12	0-081	0-072	0-14

Goal number	
Actinic keratosis	1
Basal cell carcinoma	6
Benign keratosis	3
Dermatofibroma	1
Melanoma	1
Not trained	5
Nevi	8
Squamous cell carcinoma	1
Vascular lesion	1

Table 1: Goal distribution of diagnoses included in a set of 30 images in the reader study


بحث

چالش و تحلیل طبقه‌بندی تصویر ما نشان می‌دهد که در مقایسه با یک معیار کنترل‌شده منتشر شده قبلی (HAM10000) ، دقت چندکلاسه متعادل روش‌های پیشرفته طبقه‌بندی تصویر در مجموعه داده‌هایی که به طور خاص برای بازتاب بهتر واقعیت‌های بالینی طراحی شده‌اند، بیش از ۲۰٪ کاهش می‌یابد. به طور کلی، دقت متعادل ۶۳.۶٪ برای بهترین الگوریتم کاهش قابل توجهی در عملکرد در مقایسه با معیار قبلی ۸۶.۱٪ است. ما با گنجاندن تصاویری با کیفیت متغیر، از مؤسسات منبع مختلف، حاوی دسته‌های تشخیصی که در مجموعه داده آموزشی ثبت نشده بودند، و حاوی آرטיפکت‌های تصویربرداری کمی‌شده در هر دو مجموعه داده آموزشی و آزمایشی، استفاده بالینی مورد نظر را شبیه‌سازی کردیم که همه آن‌ها در کاهش عملکرد مؤثر بودند. الگوریتم‌هایی که به طور خاص برای شکست ایمن با علامت‌گذاری تصاویر خارج از حوزه تخصص خود طراحی شده بودند، قادر به انجام این وظیفه نبودند. این یافته‌ها تعمیم‌پذیری ضعیف الگوریتم‌های پیشرفته فعلی و یک مسئله ایمنی بالقوه جدی برای استقرار بالینی را برجسته می‌کنند، علیرغم گزارش‌های قبلی AUROC بالا برای بدخیمی روی مجموعه داده‌های به خوبی کنترل‌شده.

	Readers	All algorithms	Top 3 algorithms
AK*	0.43 (0.23-0.63)	0.44 (0.42-0.46)	0.83 (0.77-0.89)
BCC*	0.70 (0.61-0.79)	0.80 (0.77-0.82)	0.91 (0.88-0.95)
BKL	0.48 (0.36-0.60)	0.37 (0.35-0.39)	0.43 (0.37-0.50)
DF*	0.50 (0.30-0.71)	0.33 (0.30-0.36)	0.73 (0.50-0.95)
MEL	0.62 (0.53-0.71)	0.58 (0.56-0.60)	0.70 (0.64-0.77)
NV*	0.56 (0.46-0.66)	0.76 (0.74-0.79)	0.76 (0.74-0.77)
NT†	0.26 (0.17-0.35)	0.06 (0.05-0.08)	0.01 (0.01-0.02)
SCC	0.65 (0.46-0.83)	0.31 (0.29-0.33)	0.62 (0.55-0.69)
VASC	0.83 (0.68-0.97)	0.46 (0.43-0.49)	0.79 (0.66-0.92)

Data are accuracy of mean count (95% CI). Mean count of correct reader classifications in batches of 30 lesions was 15.7 (95% CI 14.46-16.94). Mean count of correct algorithm (best) classifications in batches of 30 lesions was 18.95 (18.20-19.70). AK=actinic keratosis, BCC=basal cell carcinoma, BKL=benign keratosis, DF=dermatofibroma, MEL=melanoma, NT=not trained, NV=nevus, SCC=squamous cell carcinoma, VASC=vascular lesion. *Top three algorithms (average) performed >20% better than readers. †Readers performed >20% better than algorithms.

Table 2: Summary of reader accuracy versus that of automated classifiers



عملکرد ضعیف الگوریتم‌ها در دسته NT پیامدهای مهمی برای عمل بالینی دارد. دسته NT تنها ۱۱٪ از مواقع به درستی در بین ۲۵ الگوریتم برتر تشخیص داده شد. دسته NT، که عمدتاً شامل تشخیص‌های التهابی خوش‌خیم و اسکارها بود، ۴۷٪ از مواقع توسط ۲۵ الگوریتم برتر با بدخیمی اشتباه گرفته شد. تصاویر NT معمولاً با کارسینوم سلول بازال اشتباه گرفته شدند، احتمالاً به دلیل رنگ صورتی کارسینوم سلول بازال و بیشتر ضایعات در دسته NT. این نگرانی‌هایی برای اجرای بالینی ایجاد می‌کند، زیرا ۴۷٪ از ضایعات خوش‌خیم NT ممکن است در صورت اتکای تصمیمات بیوپسی به یک سیستم طبقه‌بندی خودکار برای ضایعات پوستی، بیوپسی می‌شدند. علاوه بر این، پیش‌بینی‌های مثبت کاذب بدخیمی به اضطراب و نگرانی بیمار کمک خواهد کرد. اگرچه دسته NT برای خوانندگان متخصص بالینی نیز چالش‌برانگیز بود، خوانندگان به طور متوسط به طور قابل توجهی بهتر از الگوریتم‌ها عمل کردند (۲۶٪ در مقابل ۶٪ صحیح، $p < 0.0001$ ملانوما، کراتوزهای خوش‌خیم و کراتوزهای اکتینیک اغلب با یکدیگر اشتباه گرفته شدند. ویژگی‌های غیرمعمول بالینی دقت پیش‌بینی‌های الگوریتم‌ها را در مقایسه با تصاویر فاقد آن ویژگی‌ها کاهش داد، مانند کاهش مشاهده‌شده بین خال‌های رنگدانه‌دار در مقابل فاقد رنگدانه (۸۳٪ صحیح در مقابل ۳۵٪ صحیح) و ملانوما (۷۱٪ صحیح در مقابل ۴۶٪ صحیح). همچنین مشخص شد که مؤسسه منبع بر خطاهای طبقه‌بندی تأثیر می‌گذارد که چالش‌های تعمیم الگوریتم را برجسته می‌کند. این نتایج برجسته می‌کنند که الگوریتم‌ها باید بر روی انواع معمول و غیرمعمول ضایعات و ویژگی‌های تصویربرداری آزمایش شوند، و نیاز به الگوریتم‌هایی با قابلیت قوی برای شناسایی تصاویر خارج از توزیع‌های آموزشی خود وجود دارد. باید در هنگام در نظر گرفتن اجرای پیش‌بینی‌های طبقه‌بندی خودکار در گردش کارهای بالینی احتیاط کرد، به ویژه در بازنمایی‌های بالینی غیرمعمول (مانند خال‌های دارای دلمه، که تنها در ۳۴.۷٪ موارد به درستی طبقه‌بندی شدند). (تحلیل

دقیق توزیع عملکرد الگوریتم بر روی داده‌های آزمایشی بر اساس ویژگی‌های مختلف، مانند منبع تصویر، محل آناتومیک، ویژگی‌های تصویر و ویژگی‌های بالینی، به دینفعان کمک خواهد کرد تا بفهمند چگونه الگوریتم‌ها را در مطالعات آینده‌نگر مستقر کنند.

نتایج مقایسه ما بین درماتولوژیست‌های دارای مورد و ارسال‌های چالش هوش مصنوعی با گزارش‌های قبلی سازگار است. به طور متوسط، الگوریتم‌ها به دقت بالاتری نسبت به اکثر خوانندگان متخصص دست یافتند (به جز بهترین متخصصان که برای بدخیمی از الگوریتم‌ها بهتر عمل کردند). با این حال، تا آنجا که ما می‌دانیم، این مطالعه اولین مطالعه‌ای است که گروهی از ضایعات، دسته‌های NT، را شناسایی می‌کند که برای آن‌ها خوانندگان متخصص از رویکردهای خودکار بهتر عمل کردند. این نتیجه مسائل ایمنی نگران‌کننده‌ای را در مورد استقرار الگوریتم‌های خودکار در محیط‌های بالینی آشکار می‌کند و نیاز به طراحی روش‌های بهتر برای شناسایی تصاویر خارج از حوزه تخصص یک الگوریتم برای اجتناب از بیوپسی‌های غیرضروری یا ملانوماهای از دست رفته - که هر دو در صورت استقرار الگوریتم‌های آزمایش‌شده در این کار رخ می‌دادند.

این تحلیل چندین محدودیت دارد. اول، ارائه فراداده پیش‌بینی‌های الگوریتم را بهبود بخشید، اما اندازه اثر کوچک بود. این اندازه اثر کوچک احتمالاً به دلیل فراداده اندکی است که برای گنجاندن در تصاویر در دسترس بودند. به عنوان مثال، ممکن است بتوان سن را از میزان آسیب آفتاب قابل مشاهده روی پوست پس‌زمینه استخراج کرد. تلاش‌های آینده می‌توانند فهرست گسترده‌تری از ویژگی‌های فراداده را برای ارزیابی عمیق‌تر این تأثیر بازبینی کنند. دوم، کاربرد این کار توسط ماهیت گذشته‌نگر جمع‌آوری تصویر، تنوع اندک در قومیت‌ها (با فرض از محل کلینیک‌ها)، عدم برچسب‌گذاری رنگ پوست تصاویر بیماران و اینکه مطالعه خواننده متخصص روی تصاویر ثابتی انجام شد که محیط بالینی را تقلید نمی‌کنند، محدود شده است. ما همچنین چندین نقطه زمانی ضایعه را گنجاندیم که دشواری برچسب‌گذاری استاندارد طلایی ملانوماهایی که از نوپلاسم‌های خوش‌خیم ایجاد می‌شوند را برجسته می‌کند. کار آینده می‌تواند این انتقال را برای بهبود شناسایی هوش مصنوعی بررسی کند. سوم، ما الگوریتم‌ها را در برابر سناریوها و جابجایی‌های آماری آزمایش کردیم که به شدت به مجموعه داده آموزشی وابسته هستند. اگرچه کاهش‌های خاص عملکردی که ما گزارش می‌دهیم ممکن است به سایر کاربردها و توزیع‌های آموزشی قابل تعمیم نباشد، ملاحظات ترسیم‌شده، آرتیفکت‌های تصویری که مشخص شد بر دقت تأثیر می‌گذارند، و شکست الگوریتم روی تصاویری که برای شناسایی آموزش ندیده است، باید برای همه کاربردها در نظر گرفته شوند. شواهد فزاینده‌ای وجود دارد که تعامل انسان و رایانه ممکن است بر دقت انسان یا هوش مصنوعی به تنهایی بهبود بخشد. کار بیشتر از یک رویکرد آینده‌نگر به طراحی مجموعه داده و آزمایش‌های نظارت‌شده نزدیک رویکردهای خودکار با پزشکان در عمل بالینی به‌رهمند خواهد شد.

به طور خلاصه، این چالش بزرگ طبقه‌بندی تصویر در موسکویی نشان داد که دقت روش‌های پیشرفته طبقه‌بندی در مجموعه داده‌هایی که به طور خاص برای بازتاب بهتر واقعیت‌های بالینی طراحی شده‌اند، بیش از ۲۰٪ در مقایسه با یک معیار کنترل‌شده قبلی کاهش می‌یابد. آرتیفکت‌های تصویربرداری کمی‌شده موجود در هر دو مجموعه داده آموزشی و آزمایشی مشخص شد که وقتی دقت بر اساس آرتیفکت‌ها و شرایط بیماری لایه‌بندی می‌شود، دقت را کاهش می‌دهند. علاوه بر این، الگوریتم‌هایی که به طور خاص برای شکست ایمن با علامت‌گذاری تصاویر خارج از داده‌های آموزشی خود طراحی شده بودند، بدتر از خوانندگان متخصص عمل کردند. این نتایج مسائل ایمنی بالقوه جدی برای استقرار بالینی را برجسته می‌کنند، علیرغم مجموعه داده‌های کنترل‌شده قبلی که AUROC بالا برای تشخیص‌هایی مانند بدخیمی گزارش کرده بودند.

داده‌ها دقت میانگین شمارش (فاصله اطمینان ۹۵٪) هستند. میانگین شمارش طبقه‌بندی‌های صحیح خواننده در دسته‌های ۳۰ ضایعه‌ای ۱۵.۷ (فاصله اطمینان ۹۵٪ ۱۶.۹۴-۱۴.۴۶) بود. میانگین شمارش طبقه‌بندی‌های صحیح الگوریتم (بهترین) در دسته‌های ۳۰ ضایعه‌ای ۱۸.۹۵ (۱۸.۲۰-۱۹.۷۰) بود.

AK=اکراتوز اکتینیک، BCC=کارسینوم سلول بازال، BKL=کراتوز خوش‌خیم، DF=درماتوفیبروما، MEL=ملانوما، NT=آموزش‌ندیده، NV=خال (نوی)، SCC=کارسینوم سلول سنگفرشی، VASC=ضایعات عروقی.

*سه الگوریتم برتر (میانگین) بیش از ۲۰٪ بهتر از خوانندگان عمل کردند.

†خوانندگان بیش از ۲۰٪ بهتر از الگوریتم‌ها عمل کردند.

مشارکت‌کنندگان

NC، AH و JM بر مطالعه نظارت کردند. AH، تأمین مالی را به دست آورد و مدیریت پروژه را انجام داد. NC، JW، نگارش اولیه مقاله را انجام دادند، تحلیل‌های رسمی داده و آماری را انجام دادند و به داده‌های زمینه‌ای دسترسی یافته و آن‌ها را تأیید کردند. MC، VR، SD، HK، CE، JW، CC، BH، NRK، KL، SPo و SPu داده‌ها را گردآوری کردند. DG، HK، MAM، CR، PT و JW مسئول روش‌شناسی تحقیق بودند. DG، HK، MAM، CR، PT، JW، CC، BH، NRK، KL، SPo، SPu، AH و JM مقاله را بازبینی و ویرایش کردند. تمام نویسندگان به داده‌های ارائه‌شده در مقاله دسترسی داشتند. VR، NC و MC، در همکاری با تمام نویسندگان، مسئول تصمیم به ارسال برای انتشار بودند.

اعلام منافع

NC در بخشی از این کار کارمند IBM بود. تنها مشارکت IBM از طریق کار NC بود. NC در حال حاضر در مایکروسافت استخدام شده است، اما تنها مشارکت مایکروسافت از طریق کار NC است. دو اختراع در مایکروسافت دارد (اختراع آمریکا ۱۰۵۶۸۶۵ B2 برای برداشتن ضایعه پوستی جراحی و اختراع آمریکا ۱۰۲۵۵۶۷۴ B2 برای کاهش بازتاب سطحی در تصاویر با استفاده از جایگزینی بخش غیرتخصصی) که مرتبط با این کار نیستند. NC گزارش می‌دهد که سهام IBM و مایکروسافت را در اختیار دارد، دریافت وجه یا حق‌الزحمه از مموریال اسلون-کترینگ و حمایت برای شرکت در جلسات یا سفر از مموریال اسلون-کترینگ و IBM. SPu از Bristol Myers Squibb، ISDIN، Admiral، Sanofi، Regeneron، Pfizer، La Roche-Posay، SunPharma مشاوره می‌کند یا حق‌الزحمه دریافت می‌کند. VR مشاور متخصص برای برندهای بهداشتی است. PT از Silverchair و Lilly حق‌الزحمه دریافت می‌کند. BH توسط Kitware استخدام شده است. AH برای Canfield Scientific مشاوره می‌کند. تمام نویسندگان دیگر هیچ تعارض منافی اعلام نمی‌کنند.

اشتراک‌گذاری داده

داده‌های فردی شرکت‌کنندگان چالش به درخواست در وبسایت بایگانی ISIC در دسترس است. این شامل تمام نتایج ارسال چالش و مقالاتی است که به تفصیل تمام رویکردهای ارسال چالش را شرح می‌دهند. این داده‌ها به طور نامحدود در اختیار هر کسی که مایل به دسترسی به آن‌ها باشد قرار خواهد گرفت. داده‌های آموزشی برای چالش ۲۰۱۹ در <https://challenge.isic-archive.com/landing/2019> در دسترس است. الگوریتم‌ها به صورت عمومی بر روی داده‌های آزمایشی ۲۰۱۹ مورد استفاده در این مطالعه از طریق پلتفرم چالش ISIC در دسترس هستند.

سپاس‌گزاری

این کار توسط کمک‌های مرکز سرطان مؤسسات ملی بهداشت/مؤسسات ملی سرطان (P30 CA008748)، جایزه پژوهشگر جوان اتحاد تحقیقات ملانوما (614197)، La Marató de TV3 (718/C/2019) و صندوق Charina حمایت شده است.

References

1. Cancer Today. Population fact sheets. <https://gco.iarc.fr/today/fact-sheets-populations> (accessed July 7, 2020).

2. Gershenwald JE, Scolyer RA, Hess KR, et al. Melanoma staging: evidence-based changes in the American Joint Committee on Cancer eighth edition cancer staging manual. *CA Cancer J Clin* 2017; 67: 472–92.
3. Kim JYS, Kozlow JH, Mittal B, et al. Guidelines of care for the management of cutaneous squamous cell carcinoma. *J Am Acad Dermatol* 2018; 78: 560–78.
4. Wolner ZJ, Yelamos O, Liopyris K, Rogers T, Marchetti MA, Marghoob AA. Enhancing skin cancer diagnosis with dermoscopy. *Dermatol Clin* 2017; 35: 417–37.
5. Vestergaard ME, Macaskill P, Holt PE, Menzies SW. Dermoscopy compared with naked eye examination for the diagnosis of primary melanoma: a meta-analysis of studies performed in a clinical setting. *Br J Dermatol* 2008; 159: 669–76.
6. Conte Taboada A, Garcia Doval I, Feal C, et al. Distribución geográfica de dermatólogos y plazas MIR de dermatología en España. *Piel Form Contin En Dermatol* 2003; 18: 477–80.
7. Codella N, Gutman C, Celebi ME, et al. Skin lesion analysis toward melanoma detection: a challenge at the 2017 International Symposium on Biomedical Imaging (ISBI), hosted by the International Skin Imaging Collaboration (ISIC). *arXiv* 2018; published online Jan 8. <https://arxiv.org/abs/1710.05006v3> (preprint).
8. Codella N, Rotemberg V, Tschandl P, et al. Skin lesion analysis toward melanoma detection 2018: a challenge hosted by the International Skin Imaging Collaboration (ISIC). *arXiv* 2019; published online March 29. <http://arxiv.org/abs/1902.03368> (preprint).
9. Tschandl P, Codella N, Akay BN, et al. Comparison of the accuracy of human readers versus machine-learning algorithms for pigmented skin lesion classification: an open, web-based, international, diagnostic study. *Lancet Oncol* 2019; 20: 938–47.
10. Gutman D, Codella N, Celebi E, et al. Skin lesion analysis toward melanoma detection: a challenge at the International Symposium on Biomedical Imaging (ISBI), hosted by the International Skin Imaging Collaboration (ISIC). *arXiv* 2019; published online May 4. <https://arxiv.org/abs/1605.01397> (preprint).
11. Marchetti MA, Codella NCF, Dusza SW, et al. Results of the 2016 International Skin Imaging Collaboration International Symposium on Biomedical Imaging challenge: comparison of the accuracy of computer algorithms to dermatologists for the diagnosis of melanoma from dermoscopic images. *J Am Acad Dermatol* 2018; 78: 270–76.

12. Marchetti MA, Liopyris K, Dusza SW, et al. Computer algorithms show potential for improving dermatologists' accuracy to diagnose cutaneous melanoma: results of the International Skin Imaging Collaboration 2017. *J Am Acad Dermatol* 2020; 82: 622–27.
13. Esteva A, Kuprel B, Novoa RA, et al. Dermatologist-level classification of skin cancer with deep neural networks. *Nature* 2017; 542: 115–18.
14. Rotemberg V, Halpern A, Dusza S, Codella NC. The role of public challenges and data sets towards algorithm development, trust, and use in clinical practice. *Semin Cutan Med Surg* 2019; 38: e38–42.
15. Tschandl P, Rinner C, Apalla Z, et al. Human-computer collaboration for skin cancer recognition. *Nat Med* 2020; 26: 1229–34.
16. Maron RC, Weichenthal M, Utikal JS, et al. Systematic outperformance of 112 dermatologists in multiclass skin cancer image classification by convolutional neural networks. *Eur J Cancer* 2019; 119: 57–65.
17. Haenssle HA, Fink C, Toberer F, et al. Man against machine reloaded: performance of a market-approved convolutional neural network in classifying a broad spectrum of skin lesions in comparison with 96 dermatologists working under less artificial conditions. *Ann Oncol* 2020; 31: 137–43.
18. Sun MD, Kentley J, Mehta P, Dusza S, Halpern AC, Rotemberg V. Accuracy of commercially available smartphone applications for the detection of melanoma. *Br J Dermatol* 2021; published online Nov 22. <https://doi.org/10.1111/bjd.20903>.
19. Liang S, Srikant R, Li Y. Enhancing the reliability of out-of-distribution image detection in neural networks. *arXiv* 2020; published online Aug 30. <https://arxiv.org/abs/1706.02690> (preprint).
20. Mar VJ, Soyer HP. Artificial intelligence for melanoma diagnosis: how can we deliver on the promise? *Ann Oncol* 2019; 30: 61–3.
21. Winkler JK, Fink C, Toberer F, et al. Association between surgical skin markings in dermoscopic images and diagnostic performance of a deep learning convolutional neural network for melanoma recognition. *JAMA Dermatol* 2019; 155: 1135–41.
22. Maron RC, Hagggenmüller S, von Kalle C, et al. Robustness of convolutional neural networks in recognition of pigmented skin lesions. *Eur J Cancer* 2021; 145: 81–91.
23. Finlayson SG, Bowers JD, Ito J, Zittrain JL, Beam AL, Kohane IS. Adversarial attacks on medical machine learning. *Science* 2019; 363: 1287–89.

24. Haenssle HA, Fink C, Schneiderbauer R, et al. Man against machine: diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists. *Ann Oncol* 2018; 29: 1836–42.
25. International Skin Imaging Collaboration. ISIC 2019 leaderboards. 2019. <https://challenge.isic-archive.com/leaderboards/2019/> (accessed July 7, 2020).
26. Tschandl P, Rosendahl C, Kittler H. The HAM10000 dataset, a large collection of multi-source dermoscopic images of common pigmented skin lesions. *Sci Data* 2018; 5: 180161.
27. Combalia M, Codella NCF, Rotemberg V, et al. BCN20000: dermoscopic lesions in the wild. arXiv 2019; published online Aug 30. <http://arxiv.org/abs/1908.02288> (preprint).
28. Marchetti MA, Codella NCF, Dusza SW, et al. Results of the 2016 International Skin Imaging Collaboration International Symposium on Biomedical Imaging challenge: comparison of the accuracy of computer algorithms to dermatologists for the diagnosis of melanoma from dermoscopic images. *J Am Acad Dermatol* 2018; 78: 770–77.
29. Marchetti MA, Liopyris K, Dusza SW, et al. Computer algorithms show potential for improving dermatologists' accuracy to diagnose cutaneous melanoma: results of the International Skin Imaging Collaboration 2017. *J Am Acad Dermatol* 2020; 82: 622–27.
30. Cohn D. Active learning. In: Sammut C, Webb GI, eds. *Encyclopedia of machine learning*. Boston, MA: Springer US; 2010: 10–14.
31. Seabold S, Perktold J. Statsmodels: econometric and statistical modeling with Python. <https://conferences.scipy.org/proceedings/scipy2010/seabold.html> (accessed Oct 1, 2020).
32. Hunter JD. Matplotlib: A 2D graphics environment. *Comput Sci Eng* 2007; 9: 90–95.
33. Virtanen P, Gommers R, Oliphant TE, et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nat Methods* 2020; 17: 261–72.
34. Oliphant T. *A guide to NumPy*. Austin, TX: Continuum Press, 2006.
35. Rinner C, Kittler H, Rosendahl C, Tschandl P. Analysis of collective human intelligence for diagnosis of pigmented skin lesions harnessed by gamification via a web-based training platform: simulation reader study. *J Med Internet Res* 2020; 22: e15597.

36. Holling H, Böhning W, Böhning D. Meta-analysis of diagnostic studies based upon SROC curves: a mixed model approach using the Lehmann family. *Stat Model* 2021; 12: 347–75.
 37. Szegedy C, Ioffe S, Vanhoucke V, Alemi AA. Inception-v4, inception-ResNet and the impact of residual connections on learning. In: *Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence*. San Francisco, CA: AAAI Press; 2017: 4278–84.
 38. Ha Q, Liu B, Liu F. Identifying melanoma images using EfficientNet ensemble: winning solution to the SIIM-ISIC Melanoma Classification Challenge. *arXiv* 2020; published online Oct 11. <http://arxiv.org/abs/2010.05351> (preprint).
 39. Tan M, Le QV. EfficientNet: rethinking model scaling for convolutional neural networks. *arXiv* 2020; published online Sept 11. <http://arxiv.org/abs/1905.11946> (preprint).
 40. Pacheco AGC, Ali A-R, Trappenberg T. Skin cancer detection based on deep learning and entropy to detect outlier samples. *arXiv* 2020; published online Jan 5. <https://arxiv.org/abs/1909.04525> (preprint).
-